Исследование продаж на маркетплейсе Амазон

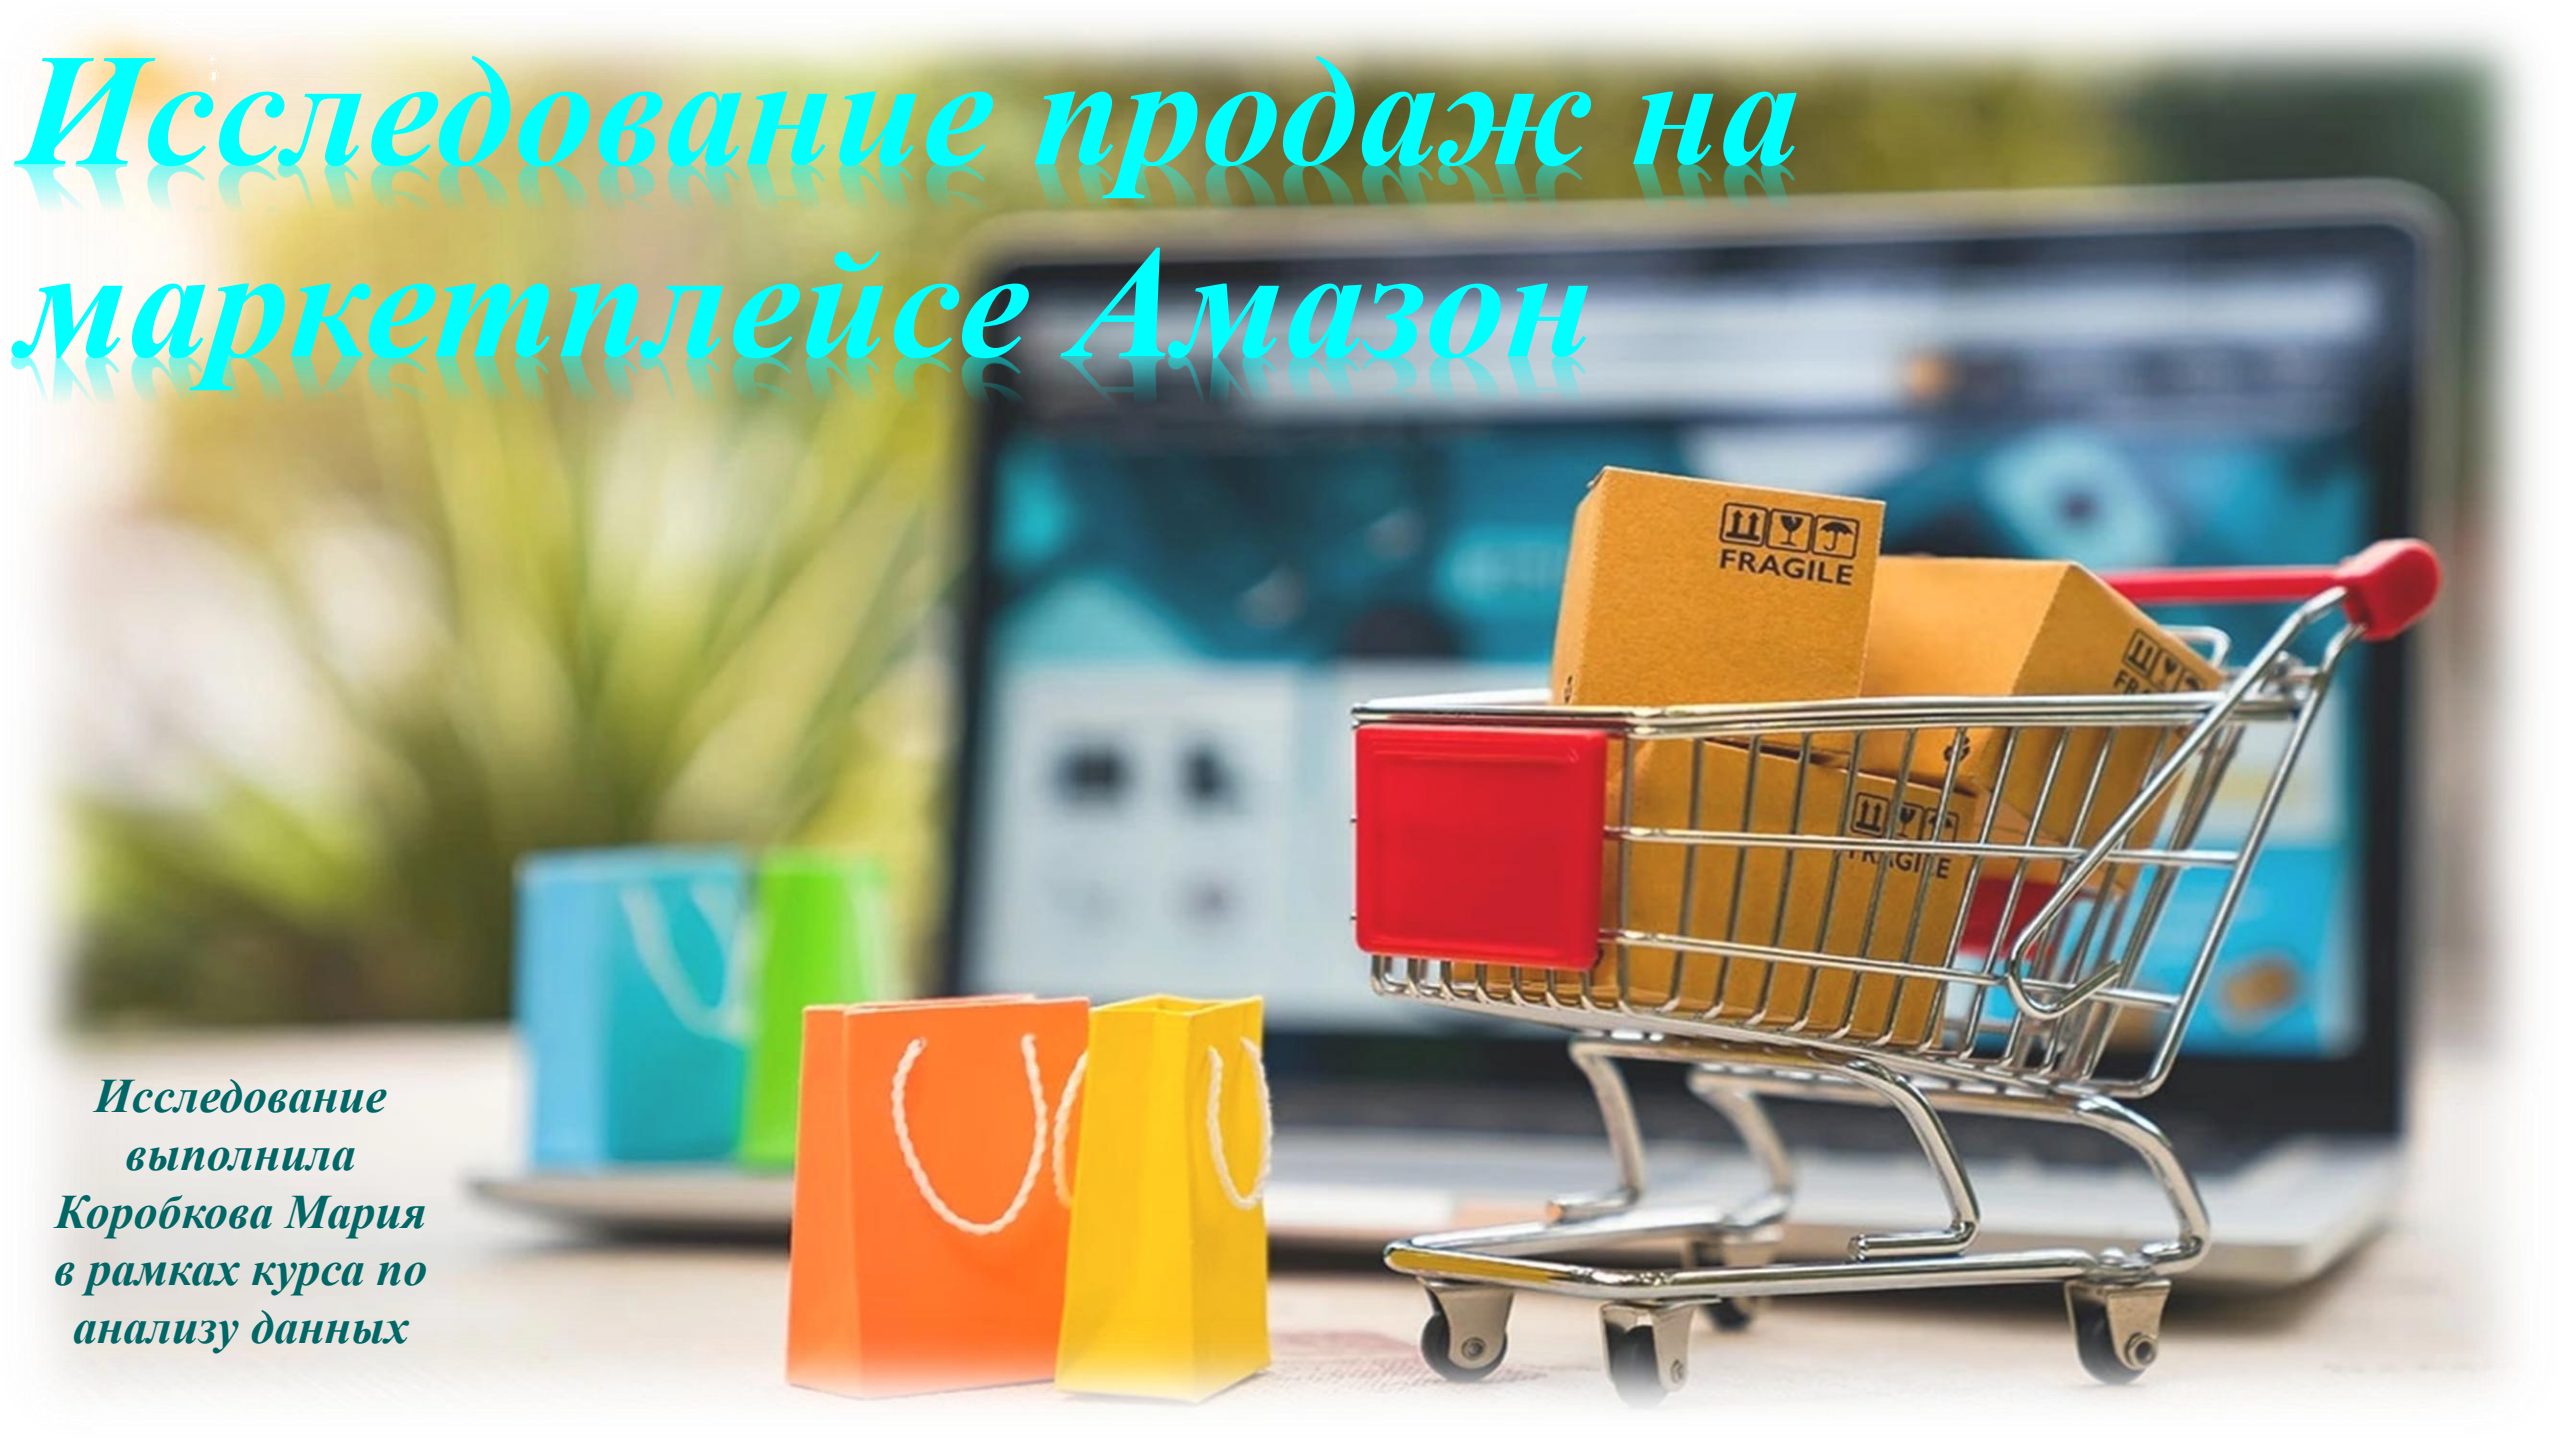

Исследование выполнила Коробкова Мария в рамках курса по анализу данных

Анализ и визуализация локации пользователей

```python
import matplotlib.pyplot as plt
import seaborn as sns

# Настройка стиля
sns.set_style("whitegrid")
plt.rcParams['figure.figsize'] = (12, 6)

# Палитра в оттенках жёлтого: от светлого к насыщенному
yellow_palette = ['#FFF9E6', '#FFE680', '#FFD633', '#E6B800', '#997300']

# === 1. Распределение по регионам ===
region_counts = df['region'].value_counts()

plt.figure(figsize=(10, 6))
plt.pie(
    region_counts.values,
    labels=region_counts.index,
    autopct='%1.1f%%',
    colors=yellow_palette[:len(region_counts)],
    startangle=90,
    textprops={'fontsize': 14, 'weight': 'bold'}
)
plt.title('Распределение клиентов по регионам', fontsize=16, weight='bold', pad=20)
plt.axis('equal')
plt.tight_layout()
plt.show()
```

```python
# === 2. Топ-10 штатов по количеству уникальных клиентов ===
top_states = df.groupby('state')['customerId'].nunique().nlargest(10)

plt.figure(figsize=(12, 7))
bars = plt.barh(
    top_states.index,
    top_states.values,
    color=yellow_palette[1]  # Основной жёлтый цвет
)

# Добавляем градиент: чем выше значение — тем темнее цвет
for i, bar in enumerate(bars):
    shade = 0.3 + (i / len(bars)) * 0.7  # градиент от светлого к тёмному
    bar.set_color(plt.cm.YlOrBr(shade))

plt.xlabel('Количество уникальных клиентов', fontsize=12)
plt.title('Топ-10 штатов по количеству клиентов', fontsize=16, weight='bold', pad=20)
plt.gca().invert_yaxis()  # Самый крупный штат сверху
plt.tight_layout()
plt.show()

# === Дополнительно: цифры для отчёта ===
print("Статистика по локациям:")
print(f"• Всего штатов: {df['state'].nunique()}")
print(f"• Всего городов: {df['city'].nunique()}")
print(f"• Топ-3 штата по клиентам:\n{top_states.head(3).to_string()}")
```

Анализ и визуализация локации пользователей

Оба графика подчеркивают неравномерность географического распределения клиентской базы, где сформирован основной объем аудитории.

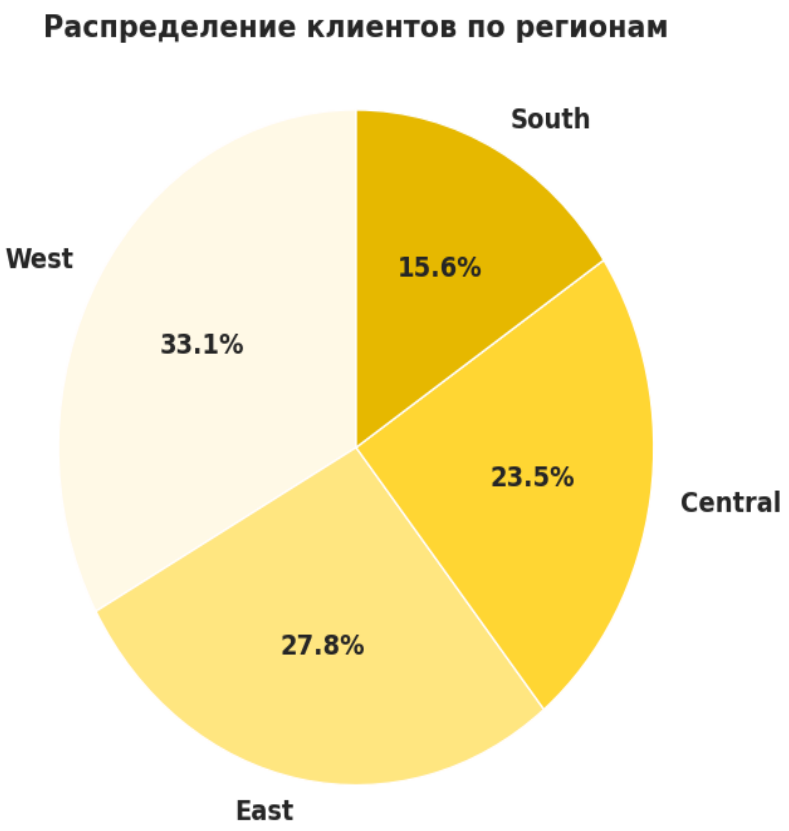

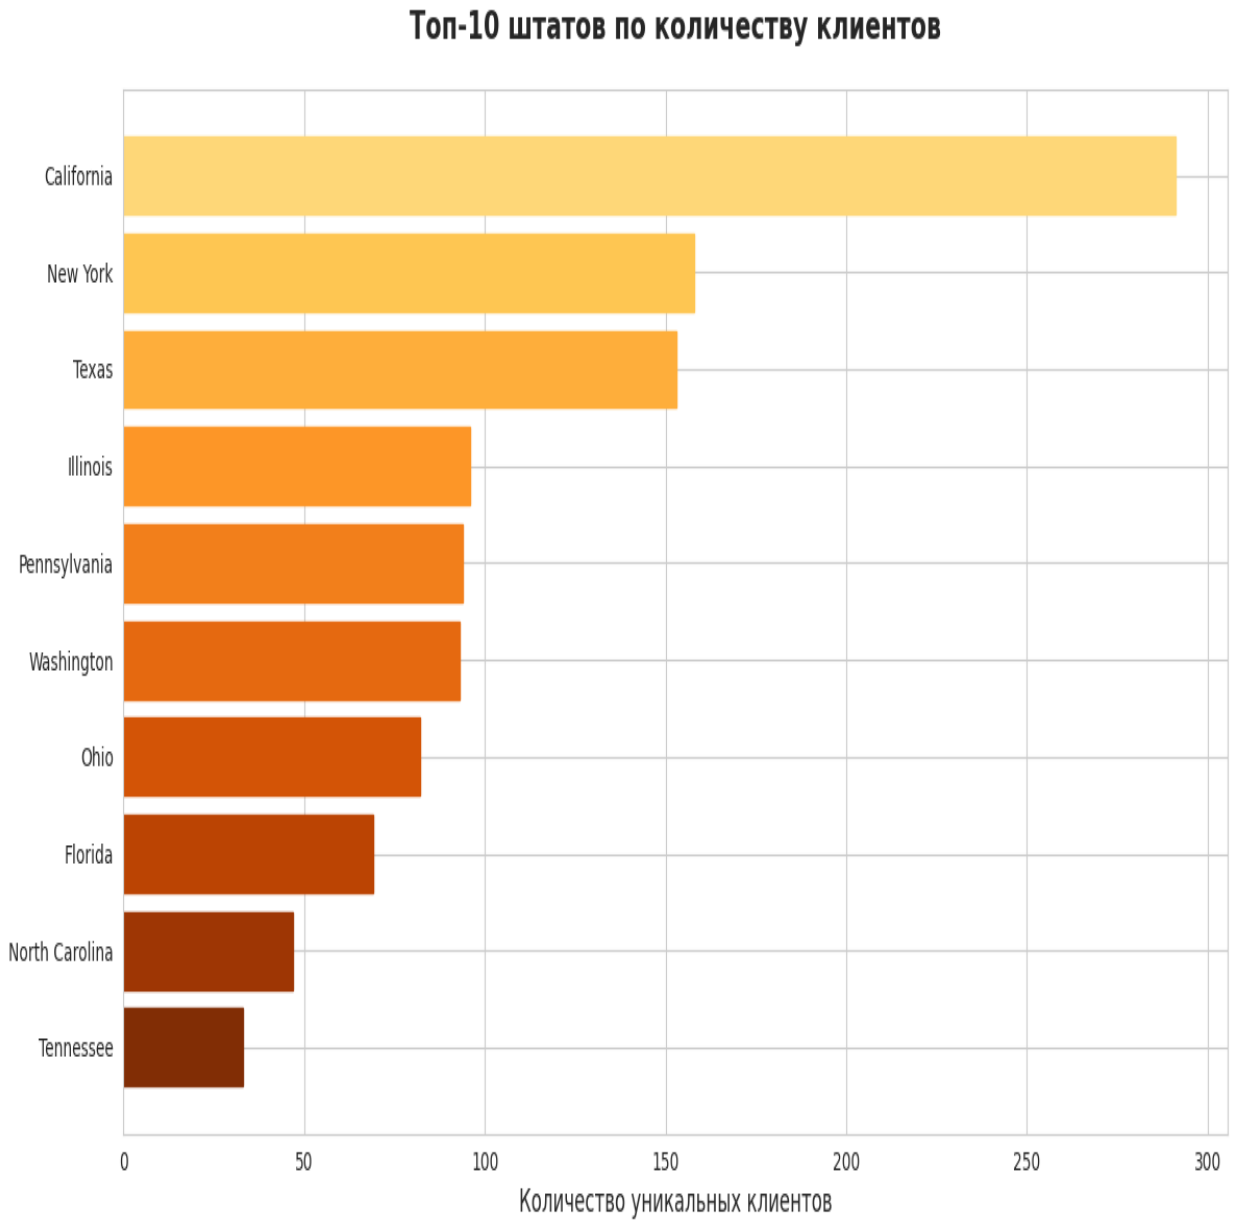

Динамика количества заказов по дате заказов

```python
# Настройка стиля
sns.set_style("whitegrid")
plt.rcParams['figure.figsize'] = (14, 6)
yellow_palette = ['#FFF9E6', '#FFE680', '#FFD633', '#E6B800', '#997300']

# === 1. Ежедневная динамика заказов ===
daily_orders = df.groupby('orderDate')['orderId'].nunique().reset_index()
daily_orders.columns = ['date', 'orderCount']

# Сглаживание: 7-дневное скользящее среднее
daily_orders['smoothed'] = daily_orders['orderCount'].rolling(window=7, center=True).mean()

plt.figure(figsize=(16, 6))
plt.plot(daily_orders['date'], daily_orders['orderCount'],
         color='#FFE680', alpha=0.4, linewidth=1, label='Факт (день)')
plt.plot(daily_orders['date'], daily_orders['smoothed'],
         color='#E6B800', linewidth=3, label='Сглажено (7 дней)')
plt.fill_between(daily_orders['date'], daily_orders['smoothed'],
                 color='#FFD633', alpha=0.3)

plt.title('Динамика количества заказов по дням', fontsize=18, weight='bold', color='#E6B800', pad=20)
plt.xlabel('Дата', fontsize=13, weight='bold')
plt.ylabel('Количество заказов', fontsize=13, weight='bold')
plt.legend(fontsize=12)
plt.grid(alpha=0.3, color='#E6B800', linestyle='--')
plt.tight_layout()
plt.show()
```

```python
# === 2. Месячная агрегация ===
df['yearMonth'] = df['orderDate'].dt.to_period('M')
monthly_orders = df.groupby('yearMonth')['orderId'].nunique().reset_index()
monthly_orders.columns = ['month', 'orderCount']
monthly_orders['month'] = monthly_orders['month'].dt.to_timestamp()

plt.figure(figsize=(16, 6))
bars = plt.bar(monthly_orders['month'], monthly_orders['orderCount'],
               color=yellow_palette[2], edgecolor=yellow_palette[4], linewidth=1.2)

# Выделим пиковые месяцы
max_idx = monthly_orders['orderCount'].idxmax()
bars[max_idx].set_color('#997300')
bars[max_idx].set_edgecolor('#664a00')
bars[max_idx].set_linewidth(2.5)

plt.title('Количество заказов по месяцам', fontsize=18, weight='bold', color='#E6B800', pad=20)
plt.xlabel('Месяц', fontsize=13, weight='bold')
plt.ylabel('Количество заказов', fontsize=13, weight='bold')
plt.xticks(rotation=45)
plt.grid(axis='y', alpha=0.3, color='#E6B800', linestyle='--')
plt.tight_layout()
plt.show()
```

Динамика количества заказов по дате заказов

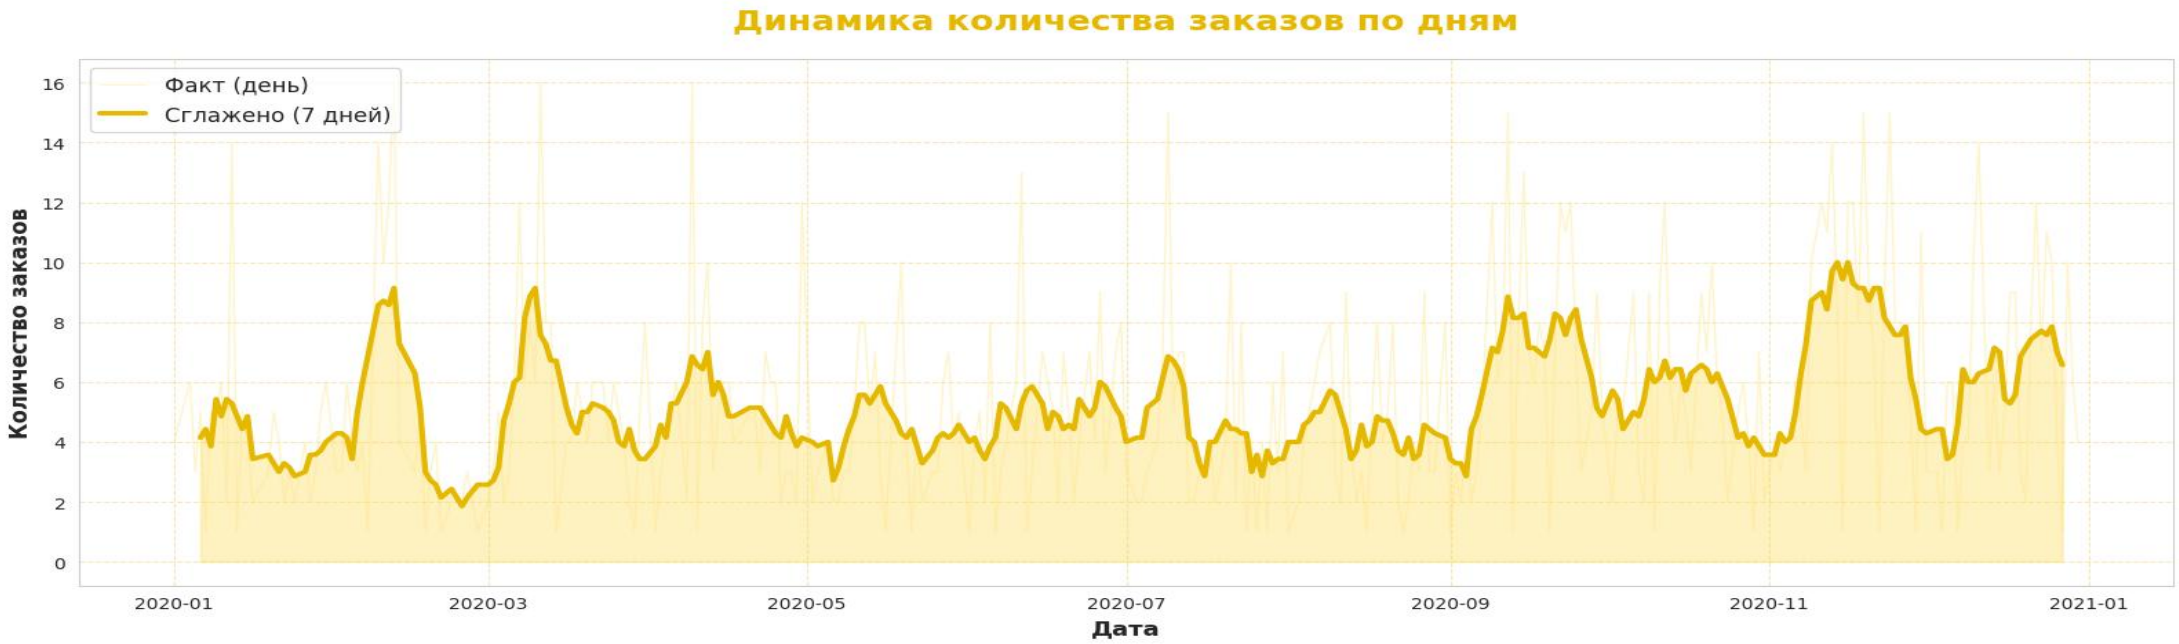

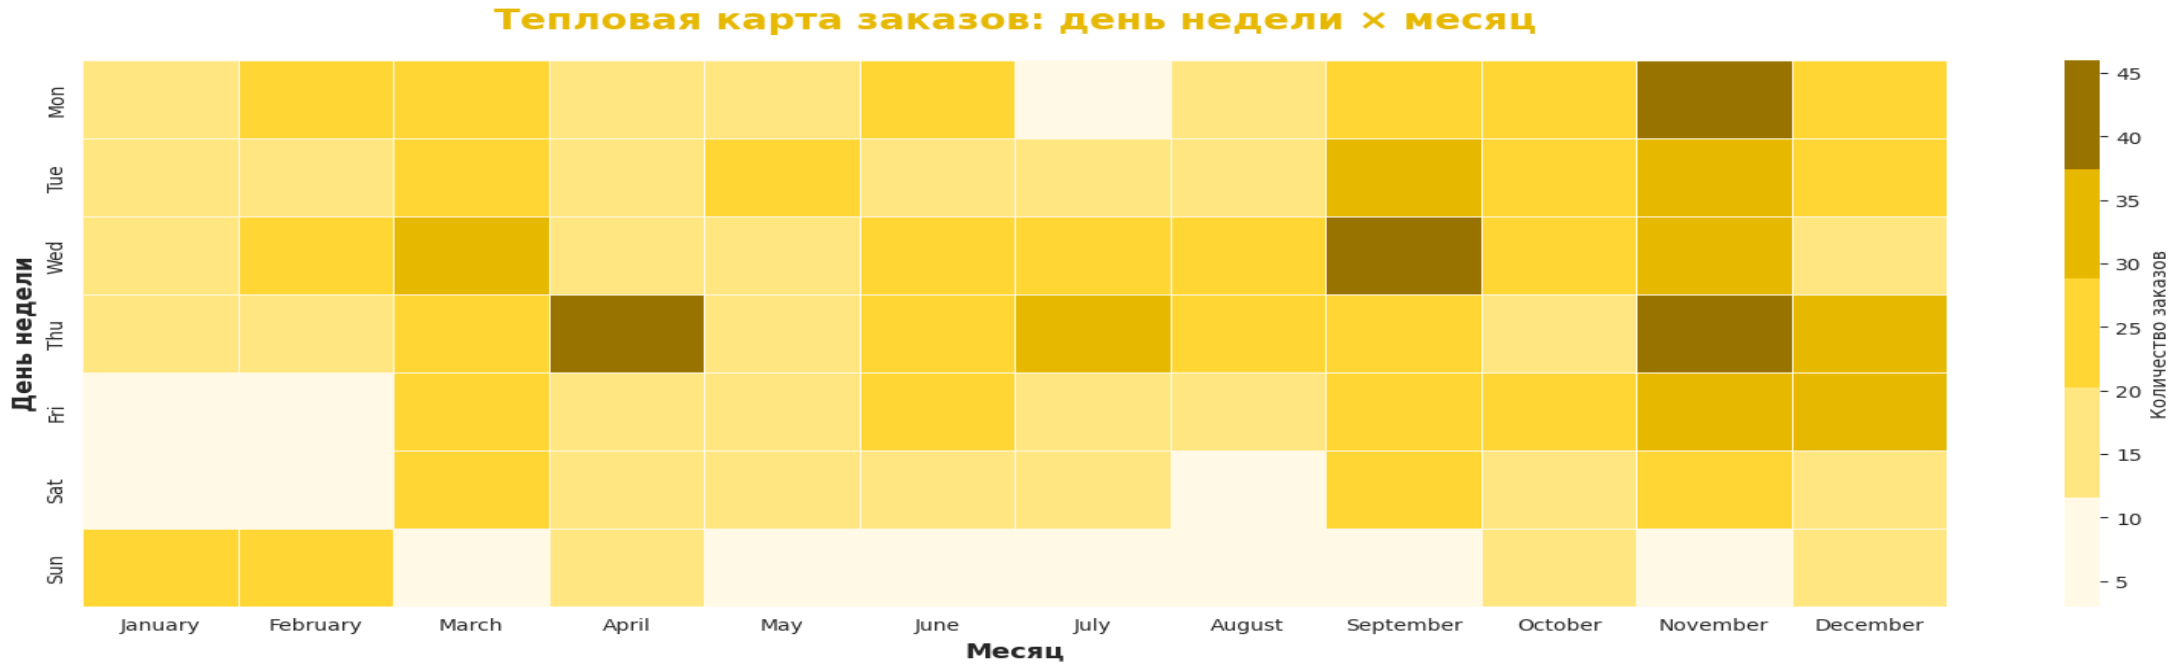

Динамика заказов по дням показывает выраженную сезонность и цикличность

Динамика продаж по дате заказов

```python
sns.set_style("whitegrid")
plt.rcParams['figure.figsize'] = (14, 6)
yellow_palette = ['#FFF9E6', '#FFE680', '#FFD633', '#E6B800', '#997300']

# === 1. Ежедневная динамика продаж ===
daily_sales = df.groupby('orderDate')['sales'].sum().reset_index()
daily_sales.columns = ['date', 'salesAmount']

# Сглаживание: 7-дневное скользящее среднее
daily_sales['smoothed'] = daily_sales['salesAmount'].rolling(window=7, center=True).mean()

plt.figure(figsize=(16, 6))
plt.plot(daily_sales['date'], daily_sales['salesAmount'],
         color='#FFE680', alpha=0.4, linewidth=1, label='Факт (день)')
plt.plot(daily_sales['date'], daily_sales['smoothed'],
         color='#E6B800', linewidth=3, label='Сглажено (7 дней)')
plt.fill_between(daily_sales['date'], daily_sales['smoothed'],
                 color='#FFD633', alpha=0.3)

plt.title('Динамика продаж (выручки) по дням', fontsize=18, weight='bold', color='#E6B800', pad=20)
plt.xlabel('Дата', fontsize=13, weight='bold')
plt.ylabel('Продажи, $', fontsize=13, weight='bold')
plt.legend(fontsize=12)
plt.grid(alpha=0.3, color='#E6B800', linestyle='--')
plt.tight_layout()
plt.show()
```

```python
# === 2. Месячная агрегация продаж ===
df['yearMonth'] = df['orderDate'].dt.to_period('M')
monthly_sales = df.groupby('yearMonth')['sales'].sum().reset_index()
monthly_sales.columns = ['month', 'salesAmount']
monthly_sales['month'] = monthly_sales['month'].dt.to_timestamp()

plt.figure(figsize=(16, 6))
bars = plt.bar(monthly_sales['month'], monthly_sales['salesAmount'],
               color=yellow_palette[2], edgecolor=yellow_palette[4], linewidth=1.2)

# Выделяем пик продаж
max_idx = monthly_sales['salesAmount'].idxmax()
bars[max_idx].set_color('#997300')
bars[max_idx].set_edgecolor('#664a00')
bars[max_idx].set_linewidth(2.5)

plt.title('Продажи по месяцам', fontsize=18, weight='bold', color='#E6B800', pad=20)
plt.xlabel('Месяц', fontsize=13, weight='bold')
plt.ylabel('Продажи, $', fontsize=13, weight='bold')
plt.xticks(rotation=45)
plt.grid(axis='y', alpha=0.3, color='#E6B800', linestyle='--')
plt.tight_layout()
plt.show()
```

Динамика продаж по дате заказов

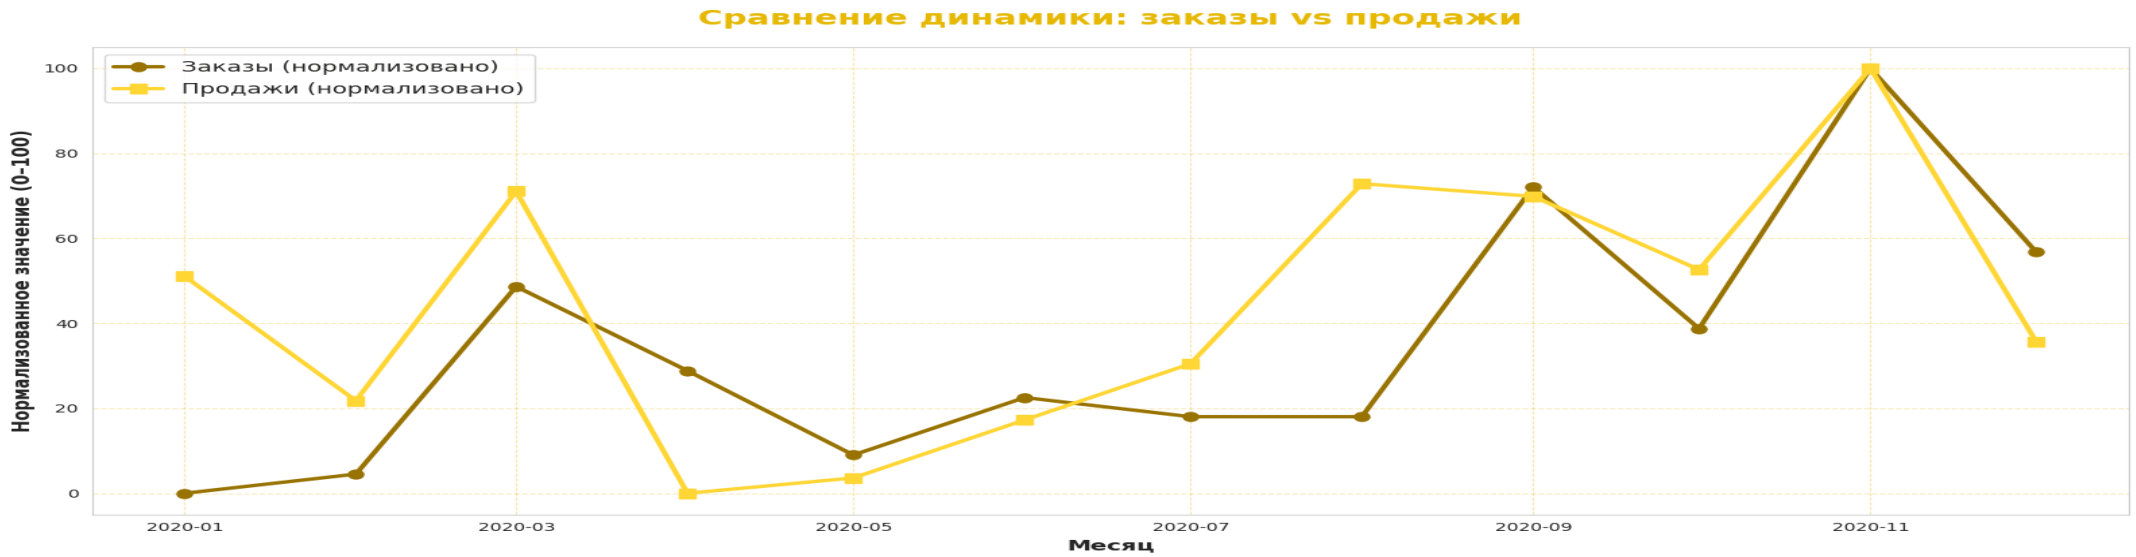

Динамика выручки по дням и месяцам демонстрирует устойчивую сезонную модель

Распределение продаж по категориям заказов

```python
import numpy as np

sns.set_style("whitegrid")
plt.rcParams['figure.figsize'] = (14, 6)
plt.rcParams['font.size'] = 12
yellow_palette = ['#FFF9E6', '#FFE680', '#FFD633', '#E6B800', '#997300']

# Агрегация данных
category_stats = df.groupby('category').agg({
    'sales': 'sum',
    'orderId': 'nunique'
}).reset_index()

category_stats.columns = ['category', 'totalSales', 'orderCount']
category_stats = category_stats.sort_values('totalSales', ascending=True).reset_index(drop=True)
```

```python
# Форматирование процентов внутри сегментов
for autotext in autotexts:
    autotext.set_color('white')
    autotext.set_weight('bold')
    autotext.set_fontsize(15)

# Добавляем легенду с абсолютными значениями
legend_labels = [f'{cat}: ${val/1000:.0f}K' for cat, val in zip(categories, sales_values)]
ax.legend(legend_labels,
          loc='center left',
          bbox_to_anchor=(1, 0, 0.5, 1),
          fontsize=13,
          frameon=True,
          facecolor='white',
          edgecolor='#E6B800',
          title='Продажи',
          title_fontsize=14)

ax.set_title('Доля категорий в общей выручке',
             fontsize=18, weight='bold', color='#E6B800', pad=20)
```

Распределение продаж по категориям заказов

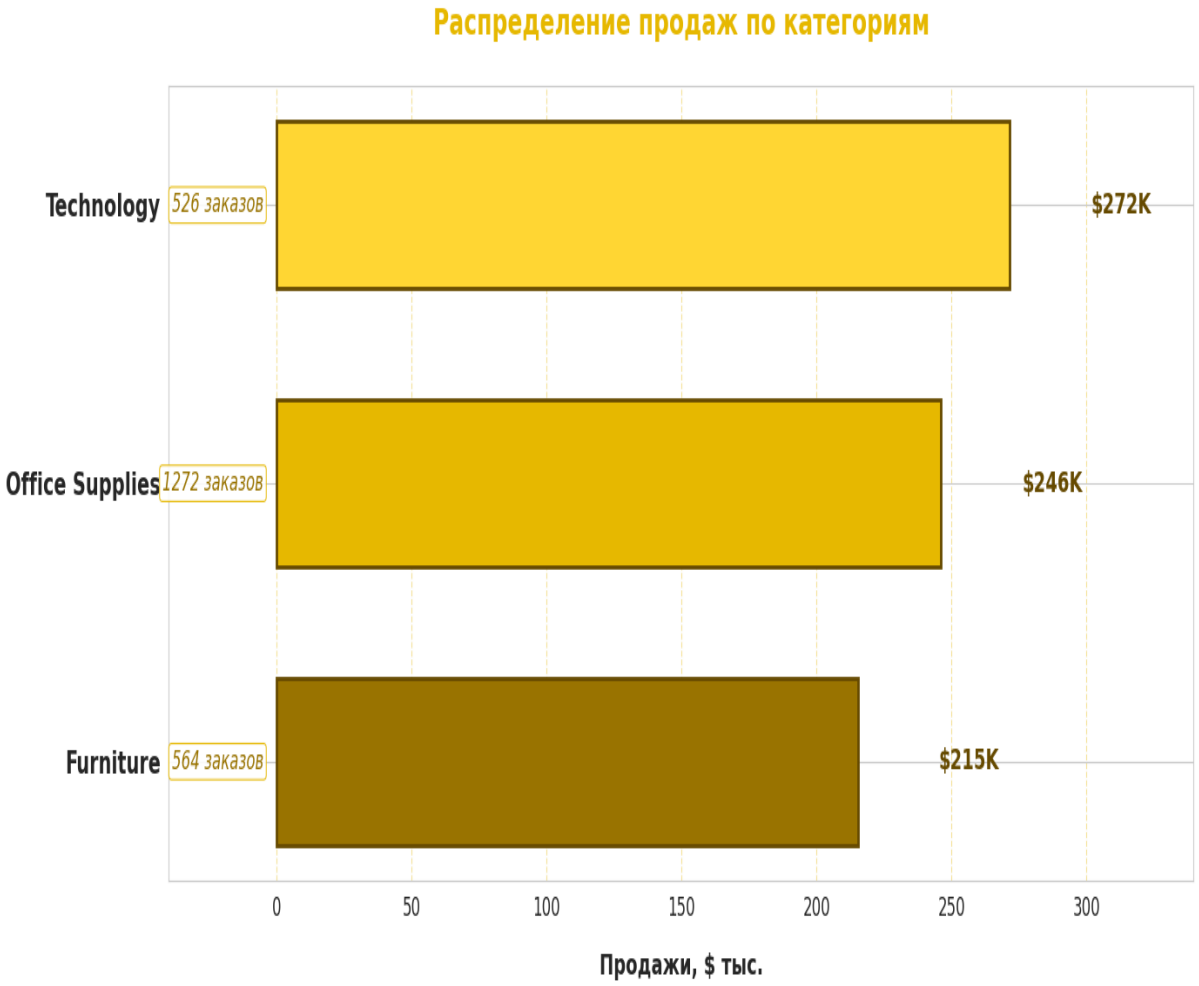

Категория Technology является лидером по выручке (272 тыс. у.е., 37.1% от общего объёма) с наименьшим количеством заказов (526), высоким средним чеком (~ 517 у.е.) и имеет стратегическую значимость для дохода.

Распределение продаж по городам (штатам)

```python
sns.set_style("whitegrid")
plt.rcParams['figure.figsize'] = (14, 7)
plt.rcParams['font.size'] = 12
yellow_palette = ['#FFF9E6', '#FFE680', '#FFD633', '#E6B800', '#997300']

# === 1. Топ-10 штатов по продажам ===
top_states_sales = df.groupby('state')['sales'].sum().nlargest(10).reset_index()

fig, ax = plt.subplots(figsize=(14, 7))
y_pos = np.arange(len(top_states_sales))

bars = ax.barh(
    y_pos,
    top_states_sales['sales'] / 1000,
    color=yellow_palette[2],
    edgecolor=yellow_palette[4],
    linewidth=2,
    height=0.6
)

# Градиент: чем выше продажи — тем темнее цвет
for i, bar in enumerate(bars):
    shade = 0.3 + (i / len(bars)) * 0.6
    bar.set_color(plt.cm.YlOrBr(shade))

# Подписи значений справа от столбцов
for i, (bar, sales) in enumerate(zip(bars, top_states_sales['sales'])):
    width = bar.get_width()
    ax.text(width + 25, bar.get_y() + bar.get_height()/2,
            f'${sales/1000:.0f}K',
            va='center', ha='left', fontsize=13, weight='bold', color='#664a00')

# Названия штатов
ax.set_yticks(y_pos)
ax.set_yticklabels(top_states_sales['state'], fontsize=14, weight='bold')

ax.set_xlabel('Продажи, $ тыс.', fontsize=14, weight='bold', labelpad=15)
ax.set_title('Топ-10 штатов по продажам',
             fontsize=18, weight='bold', color='#E6B800', pad=25)
ax.grid(axis='x', alpha=0.4, color='#E6B800', linestyle='--', linewidth=0.8)
ax.set_xlim(right=top_states_sales['sales'].max() / 1000 * 1.15)
plt.tight_layout()
plt.show()
```

```python
# === 2. Топ-10 городов по продажам ===
top_cities_sales = df.groupby('city')['sales'].sum().nlargest(10).reset_index()

fig, ax = plt.subplots(figsize=(14, 7))
y_pos = np.arange(len(top_cities_sales))

bars = ax.barh(
    y_pos,
    top_cities_sales['sales'] / 1000,
    color=yellow_palette[2],
    edgecolor=yellow_palette[4],
    linewidth=2,
    height=0.6
)

# Градиент
for i, bar in enumerate(bars):
    shade = 0.3 + (i / len(bars)) * 0.6
    bar.set_color(plt.cm.YlOrBr(shade))

# Подписи значений справа
for i, (bar, sales) in enumerate(zip(bars, top_cities_sales['sales'])):
    width = bar.get_width()
    ax.text(width + 20, bar.get_y() + bar.get_height()/2,
            f'${sales/1000:.0f}K',
            va='center', ha='left', fontsize=13, weight='bold', color='#664a00')

# Названия городов
ax.set_yticks(y_pos)
ax.set_yticklabels(top_cities_sales['city'], fontsize=14, weight='bold')

ax.set_xlabel('Продажи, $ тыс.', fontsize=14, weight='bold', labelpad=15)
ax.set_title('Топ-10 городов по продажам',
             fontsize=18, weight='bold', color='#E6B800', pad=25)
ax.grid(axis='x', alpha=0.4, color='#E6B800', linestyle='--', linewidth=0.8)
ax.set_xlim(right=top_cities_sales['sales'].max() / 1000 * 1.15)
plt.tight_layout()
plt.show()
```

Распределение продаж по городам (штатам)

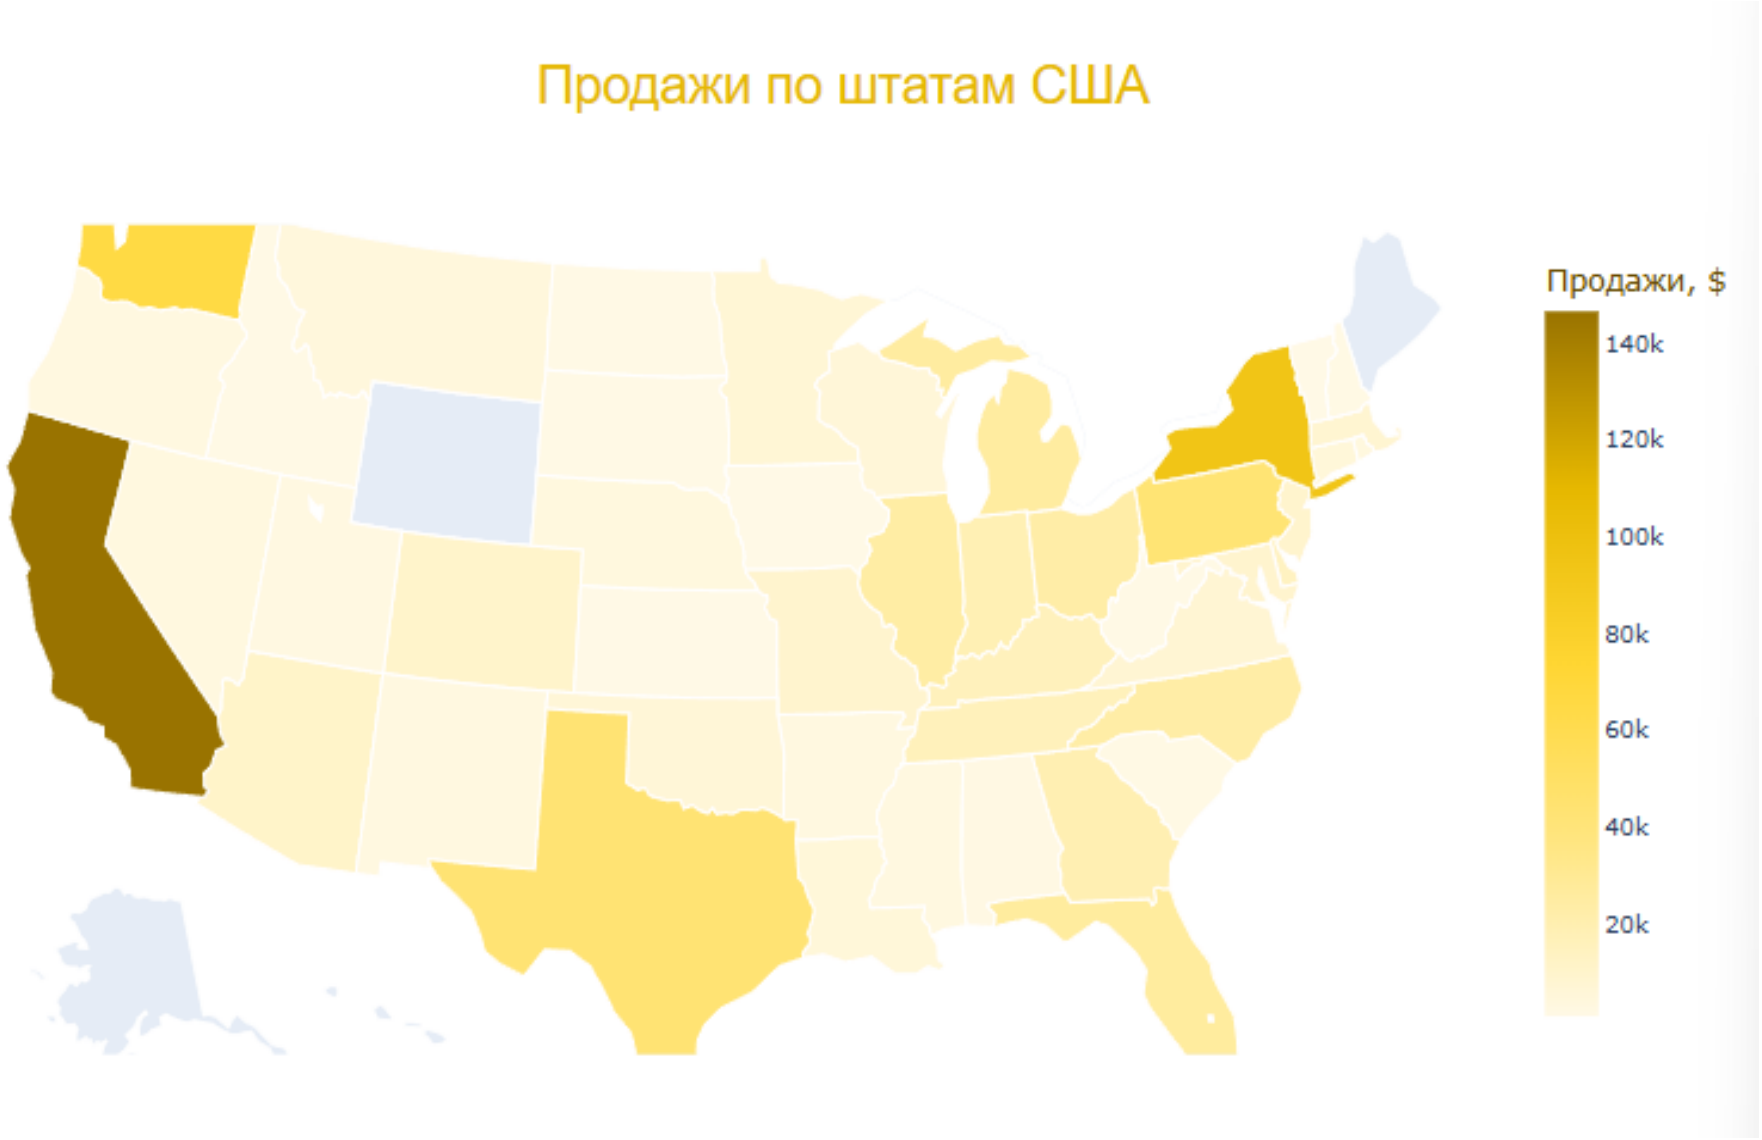

Анализ штатов по выручке показывает, что Калифорния доминирует (около 20% от общей выручки), за ней следуют Нью-Йорк и Вашингтон, что коррелирует с высокой плотностью населения и деловой активностью в этих регионах

Анализ самых популярных товаров

```python
# === 2. Топ-10 товаров по сумме продаж ===
top_products_sales = df.groupby('productName')['sales'].sum().nlargest(10).reset_index()

fig, ax = plt.subplots(figsize=(14, 7))
y_pos = np.arange(len(top_products_sales))

bars = ax.barh(
    y_pos,
    top_products_sales['sales'] / 1000,
    color=yellow_palette[3],
    edgecolor=yellow_palette[4],
    linewidth=2,
    height=0.6
)

for i, bar in enumerate(bars):
    shade = 0.3 + (i / len(bars)) * 0.6
    bar.set_color(plt.cm.YlOrBr(shade))

for i, (bar, sales) in enumerate(zip(bars, top_products_sales['sales'])):
    width = bar.get_width()
    ax.text(width + 3, bar.get_y() + bar.get_height()/2,
            f'${sales/1000:.0f}K',
            va='center', ha='left', fontsize=13, weight='bold', color='#664a00')

product_names = []
for name in top_products_sales['productName']:
    if len(name) > 35:
        product_names.append(name[:32] + '...')
    else:
        product_names.append(name)

ax.set_yticks(y_pos)
ax.set_yticklabels(product_names, fontsize=13, weight='bold')

ax.set_xlabel('Продажи, $ тыс.', fontsize=14, weight='bold', labelpad=15)
ax.set_title('Топ-10 товаров по сумме продаж',
             fontsize=18, weight='bold', color='#E6B800', pad=25)
ax.grid(axis='x', alpha=0.4, color='#E6B800', linestyle='--', linewidth=0.8)
ax.set_xlim(right=top_products_sales['sales'].max() / 1000 * 1.15)
plt.tight_layout()
plt.show()
```

[Без заголовка]

```python
# === 3. Топ-10 товаров по количеству заказов (сколько раз покупали) ===
top_products_orders = df.groupby('productName')['orderId'].nunique().nlargest(10).reset_index()
top_products_orders.columns = ['productName', 'orderCount']

fig, ax = plt.subplots(figsize=(14, 7))
y_pos = np.arange(len(top_products_orders))

bars = ax.barh(
    y_pos,
    top_products_orders['orderCount'],
    color=yellow_palette[1],
    edgecolor=yellow_palette[4],
    linewidth=2,
    height=0.6
)

for i, bar in enumerate(bars):
    shade = 0.3 + (i / len(bars)) * 0.6
    bar.set_color(plt.cm.YlOrBr(shade))

for i, (bar, orders) in enumerate(zip(bars, top_products_orders['orderCount'])):
    width = bar.get_width()
    ax.text(width + 2, bar.get_y() + bar.get_height()/2,
            f'{orders} заказов',
            va='center', ha='left', fontsize=13, weight='bold', color='#664a00')

product_names = []
for name in top_products_orders['productName']:
    if len(name) > 35:
        product_names.append(name[:32] + '...')
    else:
        product_names.append(name)

ax.set_yticks(y_pos)
ax.set_yticklabels(product_names, fontsize=13, weight='bold')

ax.set_xlabel('Количество заказов', fontsize=14, weight='bold', labelpad=15)
ax.set_title('Топ-10 товаров по частоте покупок',
             fontsize=18, weight='bold', color='#E6B800', pad=25)
ax.grid(axis='x', alpha=0.4, color='#E6B800', linestyle='--', linewidth=0.8)
ax.set_xlim(right=top_products_orders['orderCount'].max() * 1.15)
plt.tight_layout()
plt.show()
```

Анализ самых популярных товаров

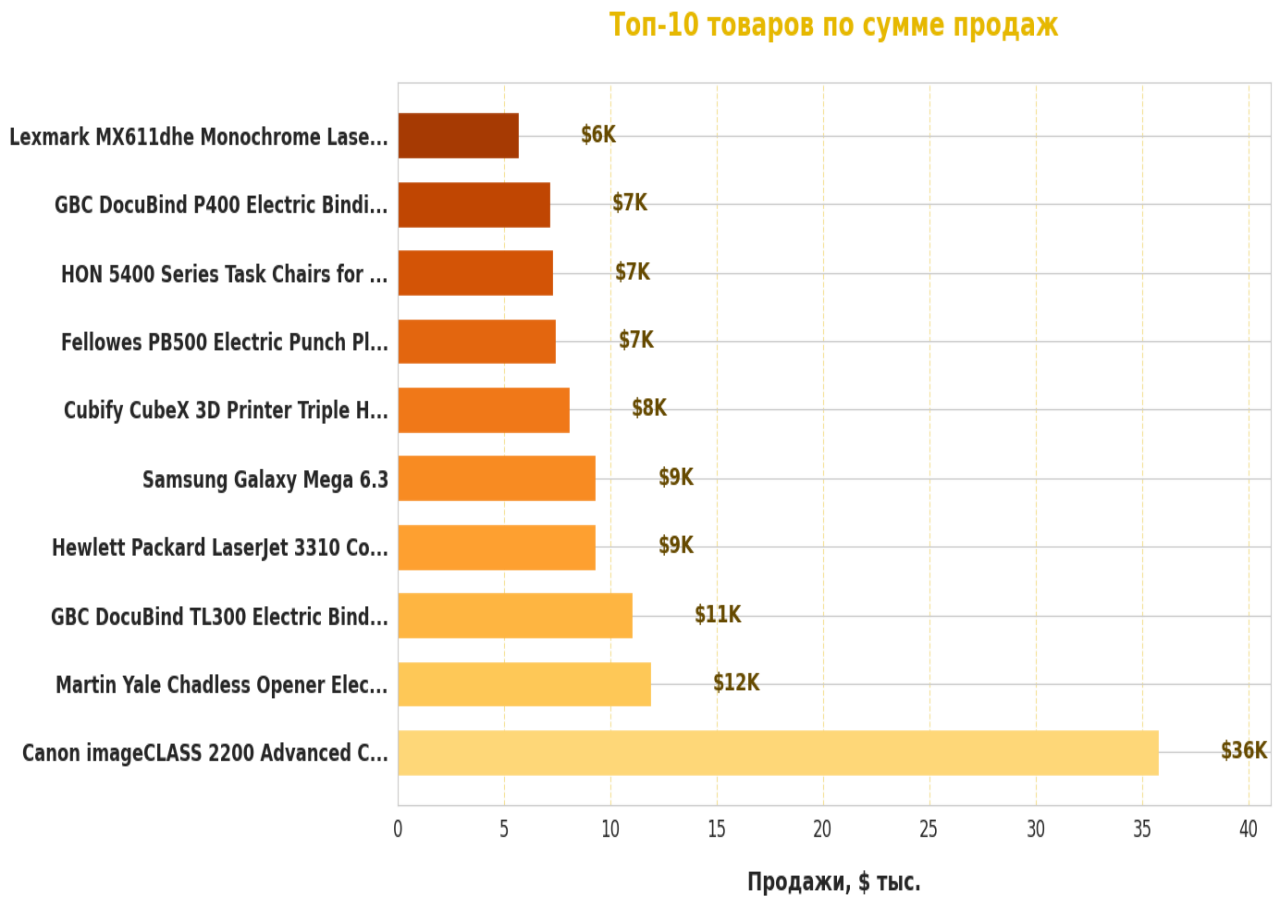

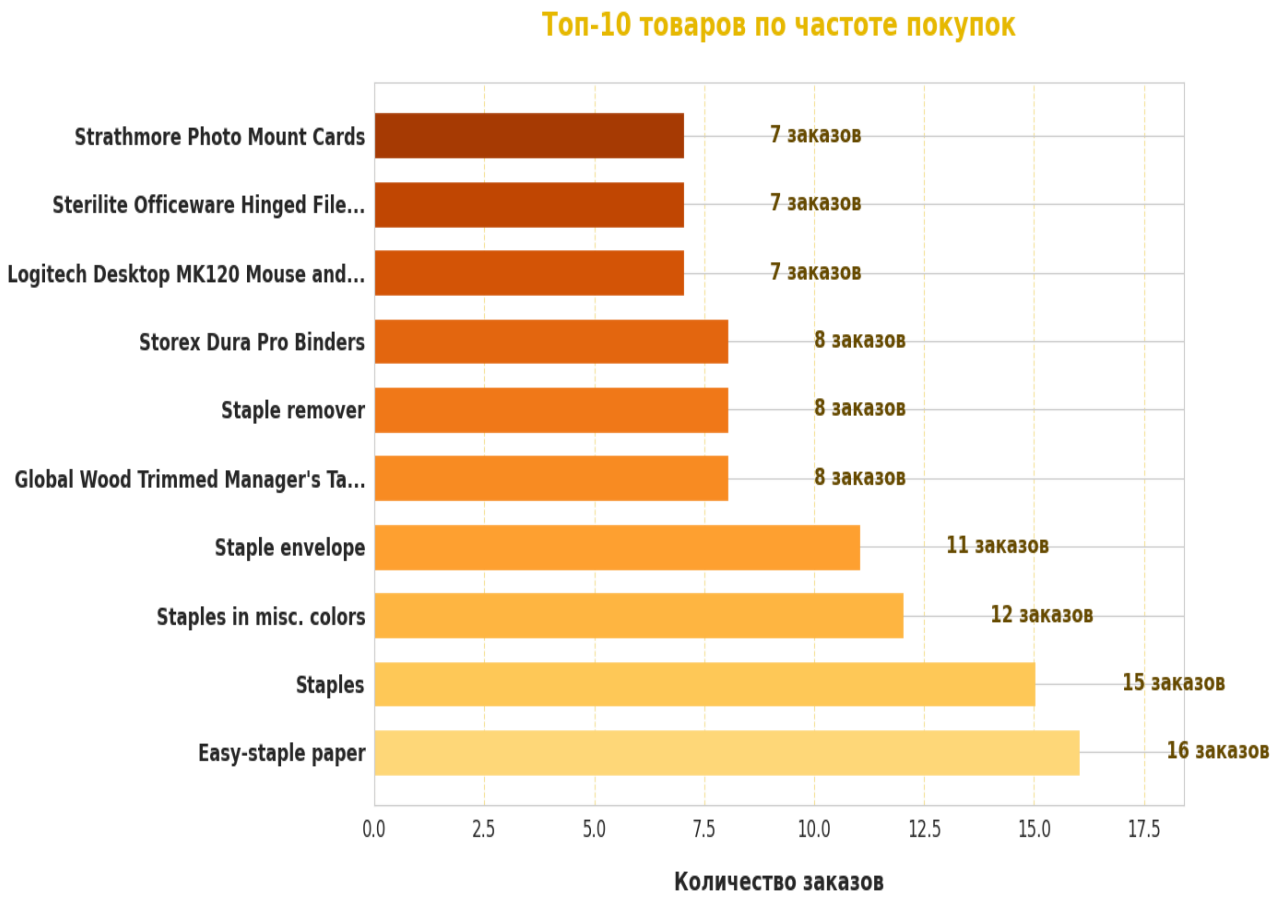

Техника — драйвер прибыли, канцелярия — драйвер лояльности — категория Technology обеспечивает 37% выручки при наименьшем числе заказов (средний чек 517 у.е.), тогда как Office Supplies формирует 56% всех заказов, но лишь 34% выручки (средний чек 194у.е.)

Динамика продаж внутри категорий

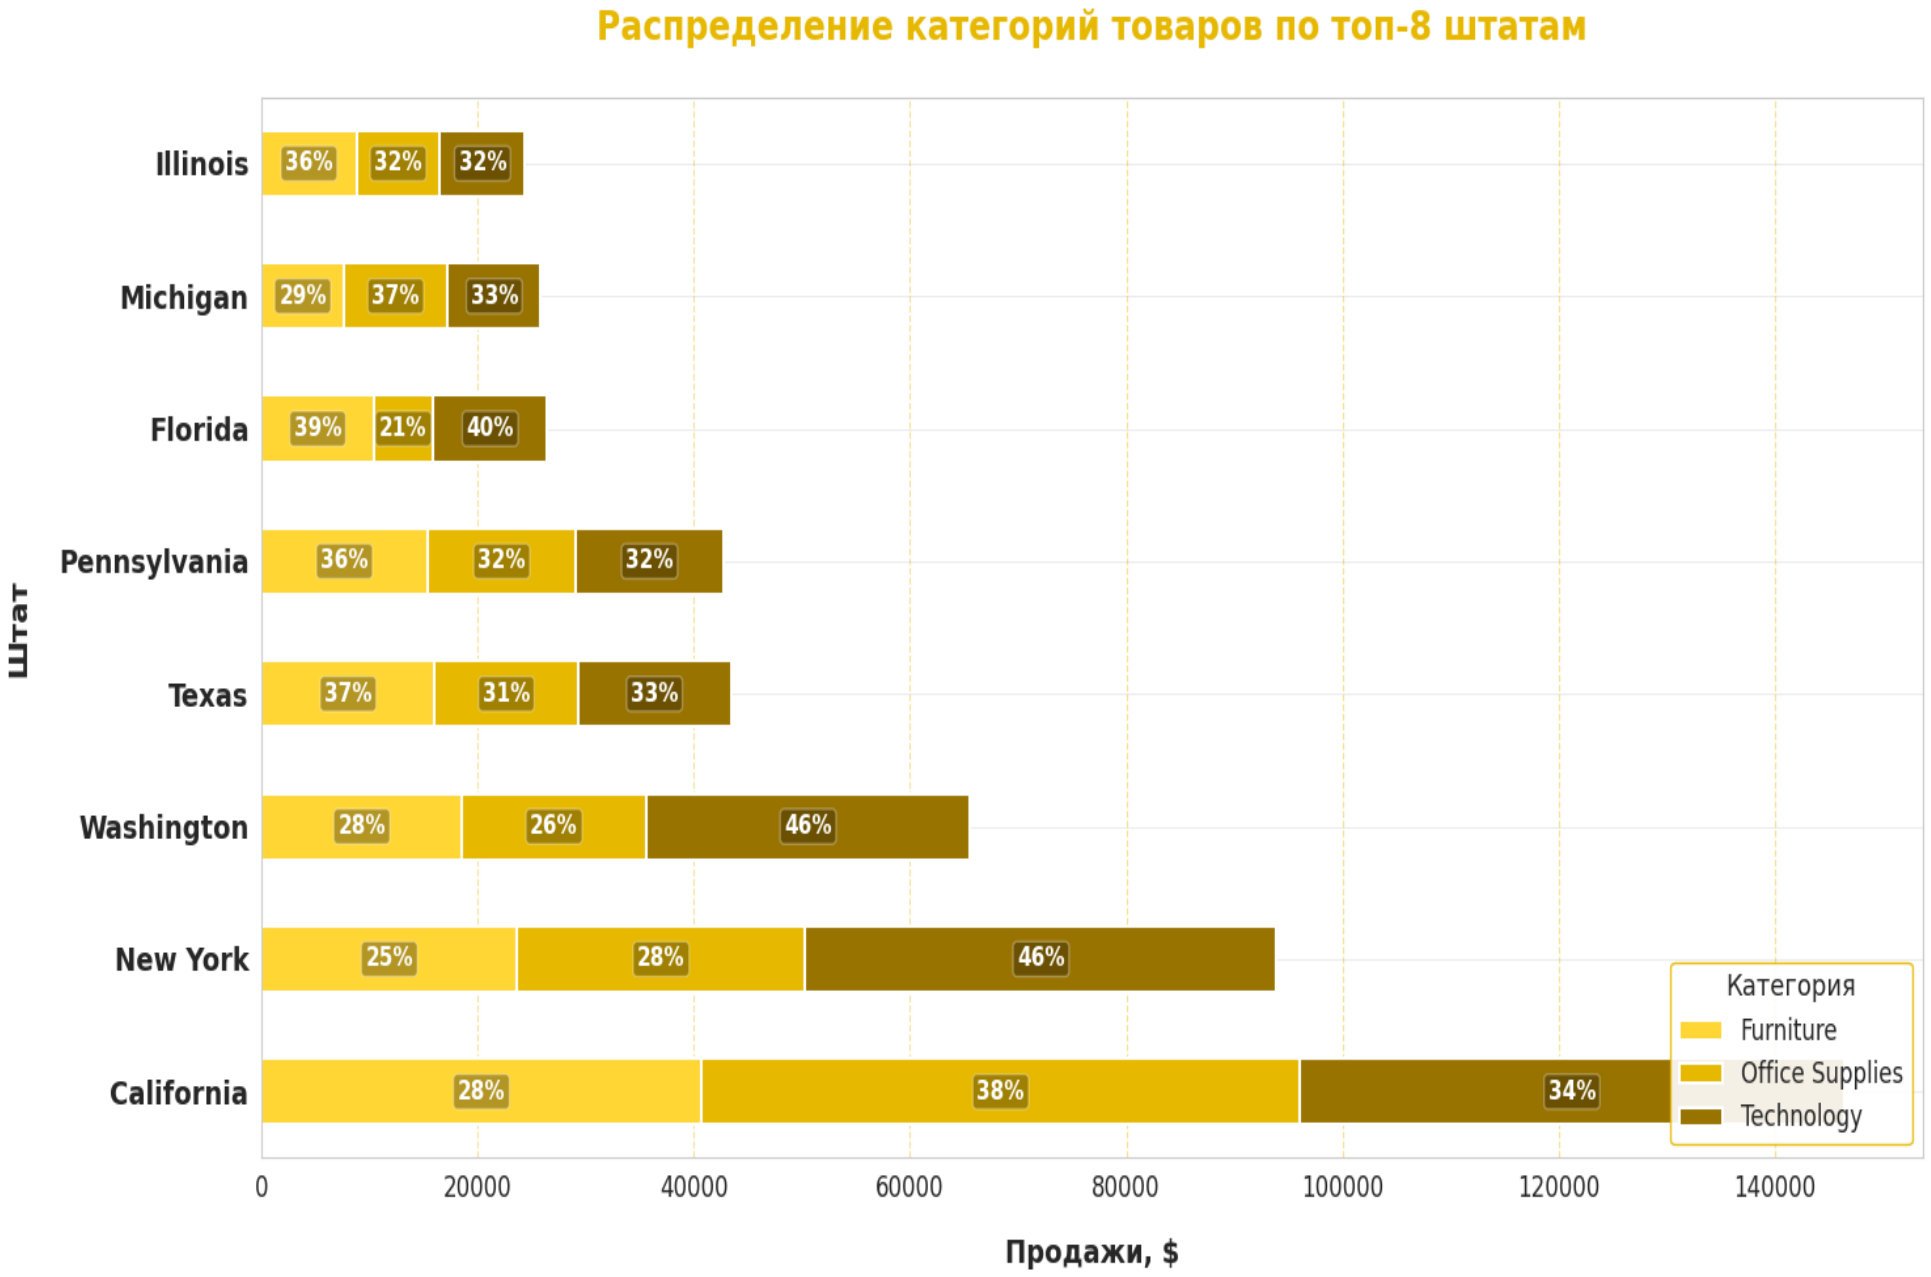

Калифорния лидирует по продажам во всех трёх категориях, демонстрируя сбалансированный спрос. В Нью-Йорке и Вашингтоне доминирует Technology (по ~46% выручки), тогда как в Техасе и Флориде выше доля Furniture (33–40%), что отражает региональные особенности потребления.

Спасибо за внимание