Исследование онлайн-сервиса Netflix

Исследование выполнила Коробкова Мария
в рамках курса по анализу данных

Изучение возраста пользователей

```python
import matplotlib.pyplot as plt
import seaborn as sns

# Единая синяя палитра
BLUE_MAIN = '#2E86AB'    # Основной синий
BLUE_LIGHT = '#A9D6E5'   # Светлый фон/заливка
BLUE_DARK = '#014F86'    # Тёмный акцент
BLUE_ACCENT = '#6B9AC4'  # Дополнительный оттенок

# Настройка стиля
sns.set_style("whitegrid", {'grid.color': '#D6E8F0', 'axes.edgecolor': BLUE_DARK})
plt.rcParams['font.family'] = 'DejaVu Sans'

# Создание фигуры
fig, axes = plt.subplots(2, 2, figsize=(14, 10))
fig.suptitle('Анализ распределения возраста', fontsize=18, fontweight='bold', color=BLUE_DARK, y=0.995)

# 1. Гистограмма + плотность
sns.histplot(df['Age'], bins=15, kde=True, ax=axes[0, 0],
             color=BLUE_MAIN, edgecolor=BLUE_DARK, linewidth=1.2)
axes[0, 0].axvline(df['Age'].mean(), color=BLUE_DARK, linestyle='--', linewidth=2,
                   label=f'Среднее: {df["Age"].mean():.1f}')
axes[0, 0].axvline(df['Age'].median(), color='white', linestyle='--', linewidth=2,
                   label=f'Медиана: {df["Age"].median():.1f}')
axes[0, 0].set_title('Гистограмма с плотностью распределения', fontsize=13, color=BLUE_DARK, pad=10)
axes[0, 0].set_xlabel('Возраст', fontsize=11)
axes[0, 0].set_ylabel('Частота', fontsize=11)
axes[0, 0].legend(facecolor=BLUE_LIGHT, edgecolor=BLUE_DARK)

# 2. Boxplot
sns.boxplot(data=df, y='Age', ax=axes[0, 1],
            color=BLUE_MAIN, width=0.5, flierprops=dict(marker='o', markerfacecolor=BLUE_DARK, markersize=6))
axes[0, 1].set_title('Boxplot: квартили и выбросы', fontsiz[Без заголовка]LUE_DARK, pad=10)
axes[0, 1].set_ylabel('Возраст', fontsize=11)
```

```python
age_stats = {
    'Среднее': df['Age'].mean(),
    'Медиана': df['Age'].median(),
    'Мода': df['Age'].mode()[0],
    'Стандартное отклонение': df['Age'].std(),
    'Минимум': df['Age'].min(),
    'Максимум': df['Age'].max(),
    'Q1 (25%)': df['Age'].quantile(0.25),
    'Q3 (75%)': df['Age'].quantile(0.75),
    'IQR': df['Age'].quantile(0.75) - df['Age'].quantile(0.25)
}
print("Статистика по возрасту:")
print("-" * 30)
for key, value in age_stats.items():
    print(f"{key:.<25} {value:>8.2f}")
```

Изучение возраста пользователей

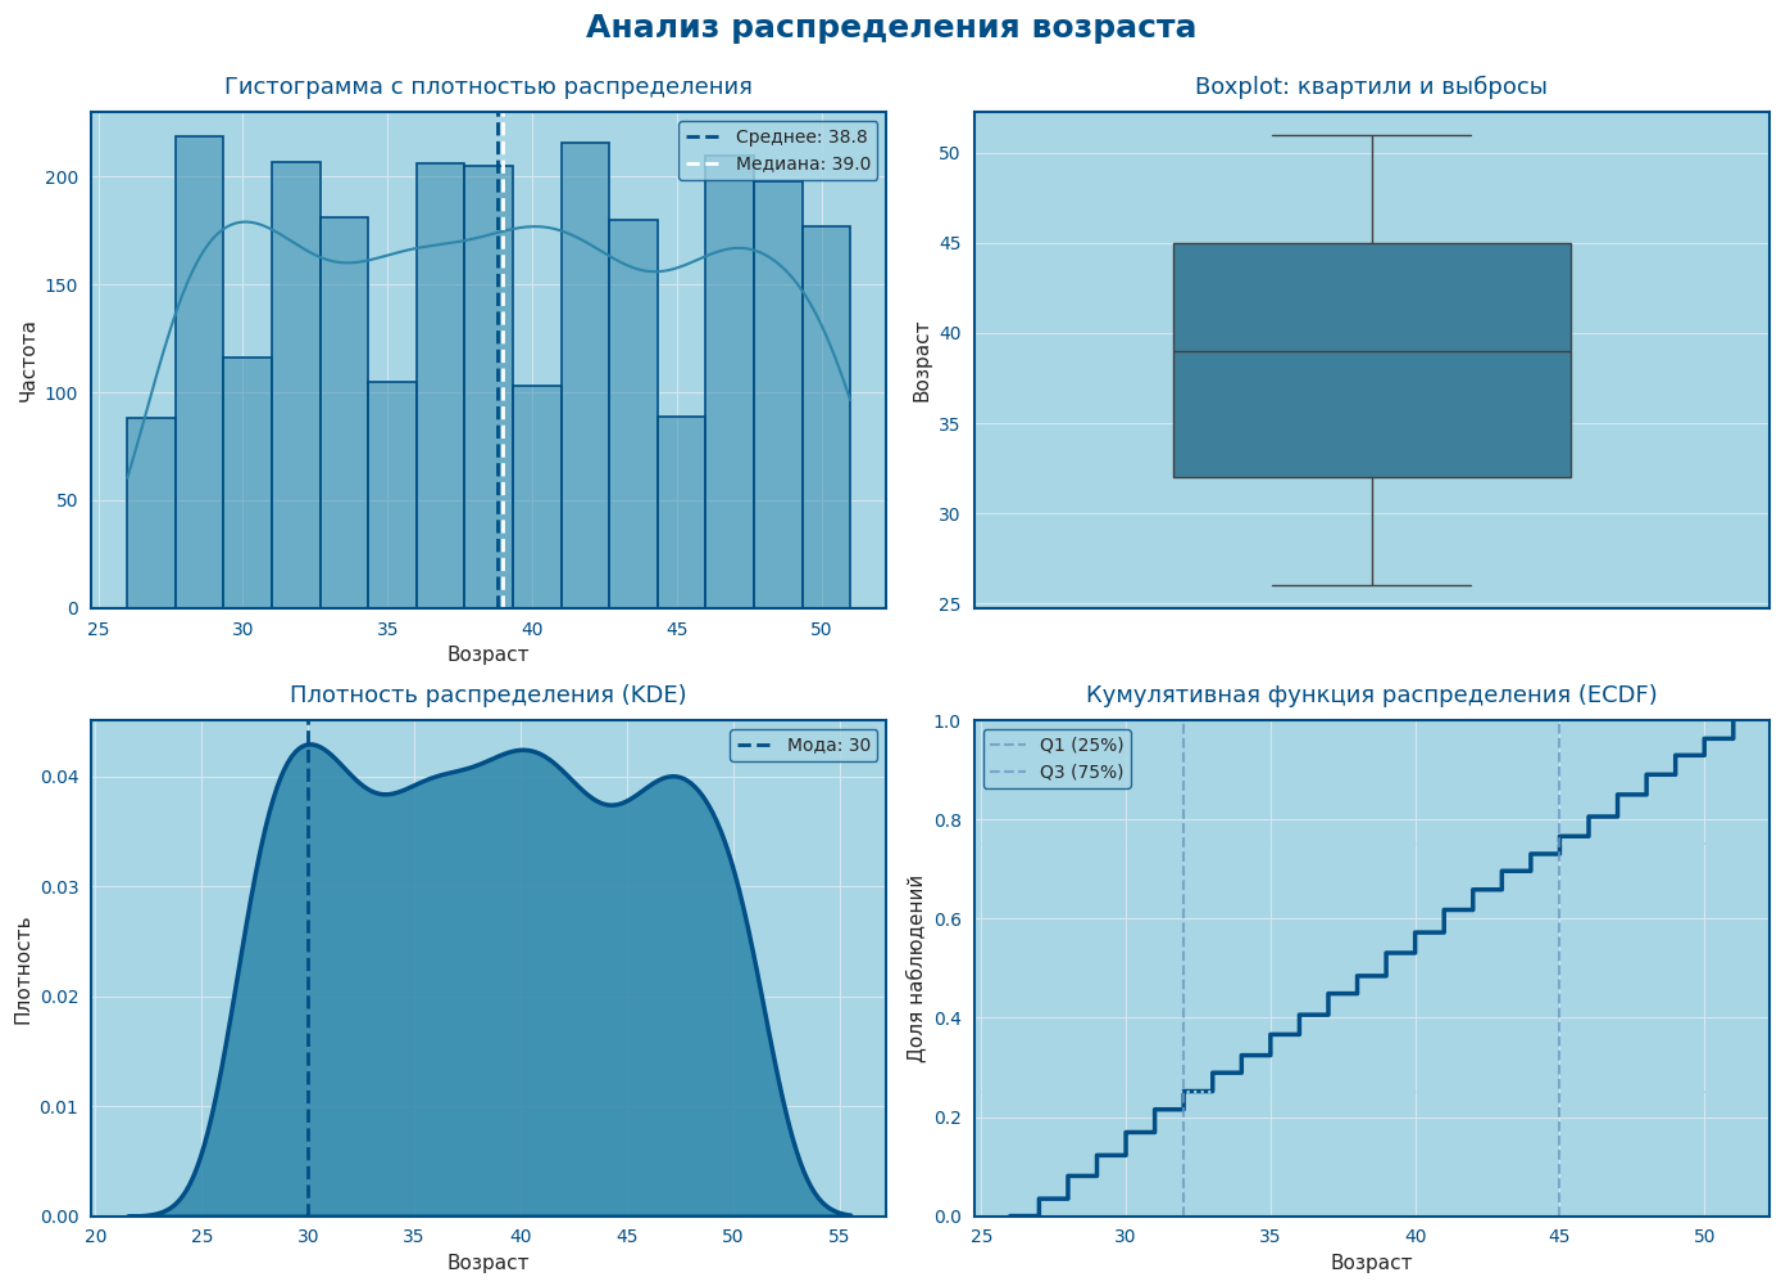

Распределение возраста демонстрирует высокую симметрию (среднее 38.8 и медиана 39.0 практически совпадают), при этом мода (30 лет) указывает на небольшой пик молодой возрастной группы в левой части распределения. Узкий межквартильный размах (IQR = 13 лет) и отсутствие выбросов в boxplot подтверждают компактное сосредоточение 50% данных в диапазоне 32–45 лет, что свидетельствует об однородности выборки.

Девайсы пользователей

```
df['Device'] = df['Device'].str.strip().str.title() #  унифицируем для корректного подсчёта

# Подсчёт распределения
device_counts = df['Device'].value_counts()
device_percent = df['Device'].value_counts(normalize=True) * 100

# Цветовая палитра (градиент синего от светлого к тёмному)
colors = ['#A9D6E5', '#89B6D0', '#6B9AC4', '#4A7BA7', '#2E86AB', '#014F86'][:len(device_counts)]

# Создание фигуры
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(15, 6))
                        [Без заголовка]
# 1. Горизонтальная столбчатая диаграмма (лучше для чтения названий)
bars = ax1.barh(device_counts.index, device_counts.values, color=colors, edgecolor='#014F86', linewidth=1.5)
ax1.set_title('Распределение пользователей по устройствам', fontsize=14, fontweight='bold', color='#014F86', pa
ax1.set_xlabel('Количество пользователей', fontsize=12)
ax1.set_ylabel('Устройство', fontsize=12)

# Добавление значений и процентов
for i, (count, pct) in enumerate(zip(device_counts.values, device_percent.values)):
    ax1.text(count + max(device_counts) * 0.02, i, f'{count} ({pct:.1f}%)',
             va='center', fontsize=11, fontweight='bold', color='#014F86')

# 2. Круговая диаграмма с выносом сегментов
explode = [0.05] * len(device_counts)  # лёгкий вынос всех сегментов для акцента
wedges, texts, autotexts = ax2.pie(
    device_counts.values,
    labels=device_counts.index,
    autopct=lambda pct: f'{pct:.1f}%\n({int(pct/100.*device_counts.sum())})',
    colors=colors,
    explode=explode,
    startangle=90,
    wedgeprops={'edgecolor': '#014F86', 'linewidth': 1.5},
    textprops={'fontsize': 11, 'fontweight': 'bold'}
)
for autotext in autotexts:
    autotext.set_color('white')
    autotext.set_fontsize(10)
ax2.set_title('Доли устройств в общем объёме', fontsize=14, fontweight='bold', color='#014F86', pad=15)

plt.tight_layout()
plt.savefig('device_distribution_blue.png', dpi=300, bbox_inches='tight', facecolor='white')
plt.show()
```

Девайсы пользователей

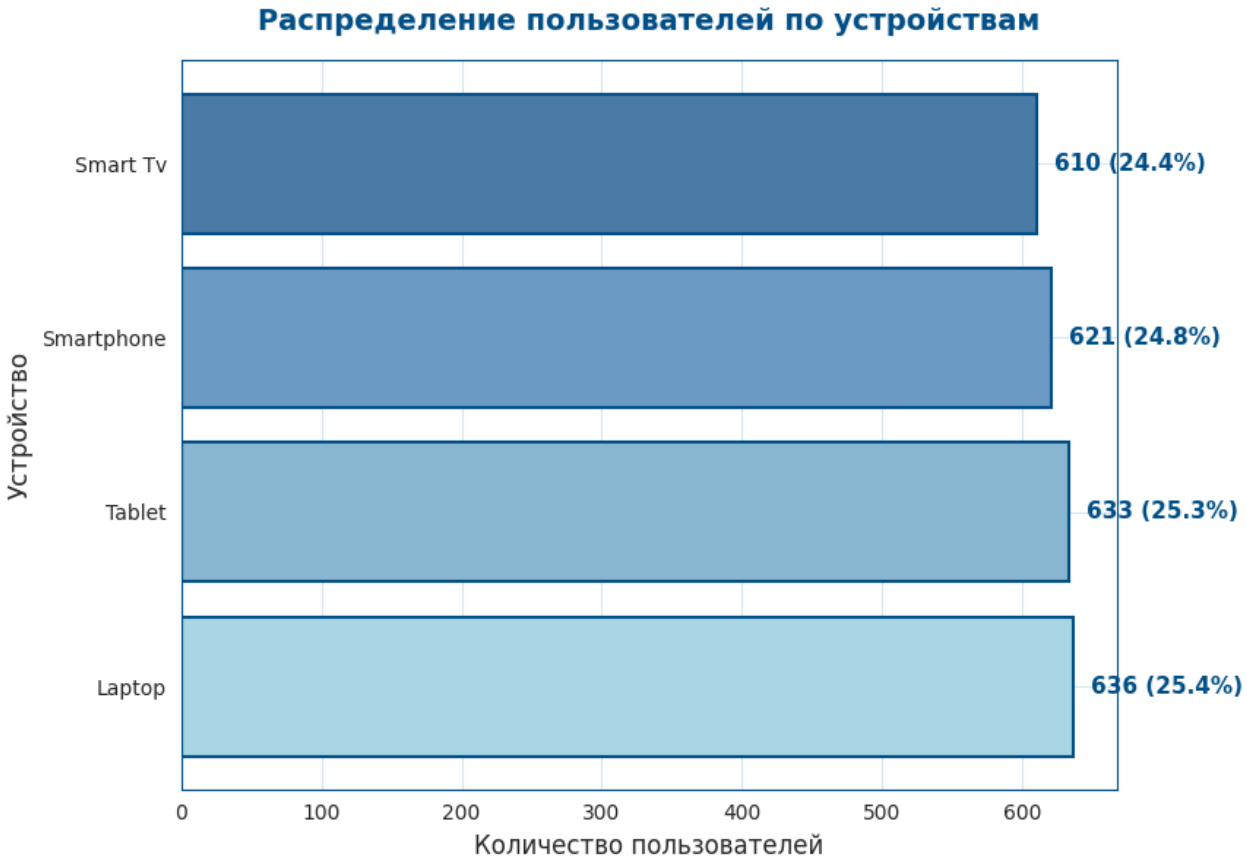

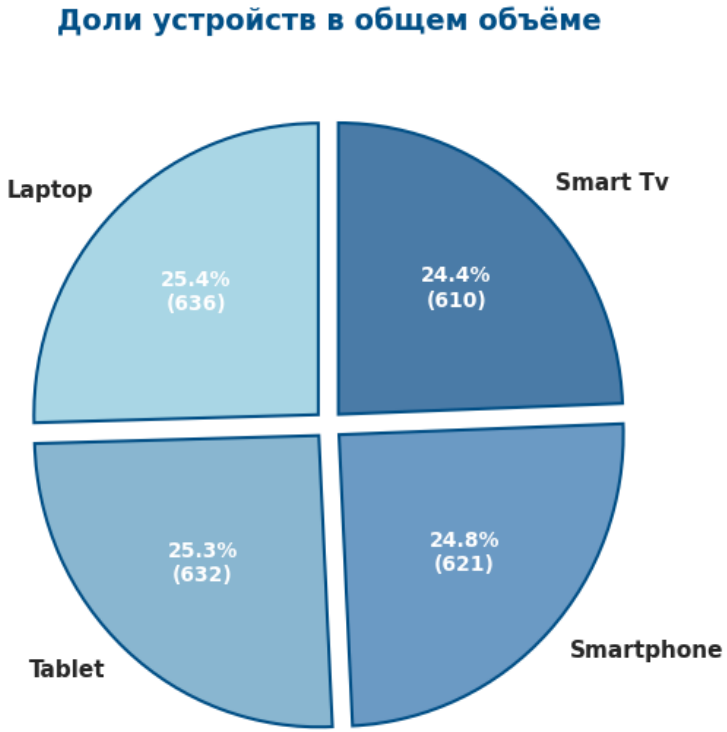

Распределение пользователей по устройствам демонстрирует равномерность: доли Laptop (25.4%), Tablet (25.3%), Smartphone (24.8%) и Smart TV (24.4%) сбалансированы, с разрывом в 1 процентный пункт между лидером и аутсайдером.

Тип подписки пользователей

```python
# Подсчёт распределения
subscription_counts = df['SubscriptionType'].value_counts()
subscription_percent = df['SubscriptionType'].value_counts(normalize=True) * 100

# Цветовая палитра (градиент синего)
colors = ['#A9D6E5', '#89B6D0', '#6B9AC4', '#4A7BA7', '#2E86AB', '#014F86'][:len(subscription_counts)]

# Создание фигуры
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(15, 6))

# 1. Вертикальная столбчатая диаграмма
bars = ax1.bar(subscription_counts.index, subscription_counts.values,
               color=colors, edgecolor='#014F86', linewidth=1.5, width=0.6)
ax1.set_title('Распределение пользователей по типу подписки', fontsize=14,
              fontweight='bold', color='#014F86', pad=15)
ax1.set_xlabel('Тип подписки', fontsize=12)
ax1.set_ylabel('Количество пользователей', fontsize=12)
ax1.set_ylim(0, max(subscription_counts) * 1.15)

# Добавление значений и процентов над столбцами
for i, (count, pct) in enumerate(zip(subscription_counts.values, subscription_percent.values)):
    ax1.text(i, count + max(subscription_counts) * 0.03, f'{count}\n({pct:.1f}%)',
             ha='center', va='bottom', fontsize=11, fontweight='bold', color='#014F86')
```

Тип подписки пользователей

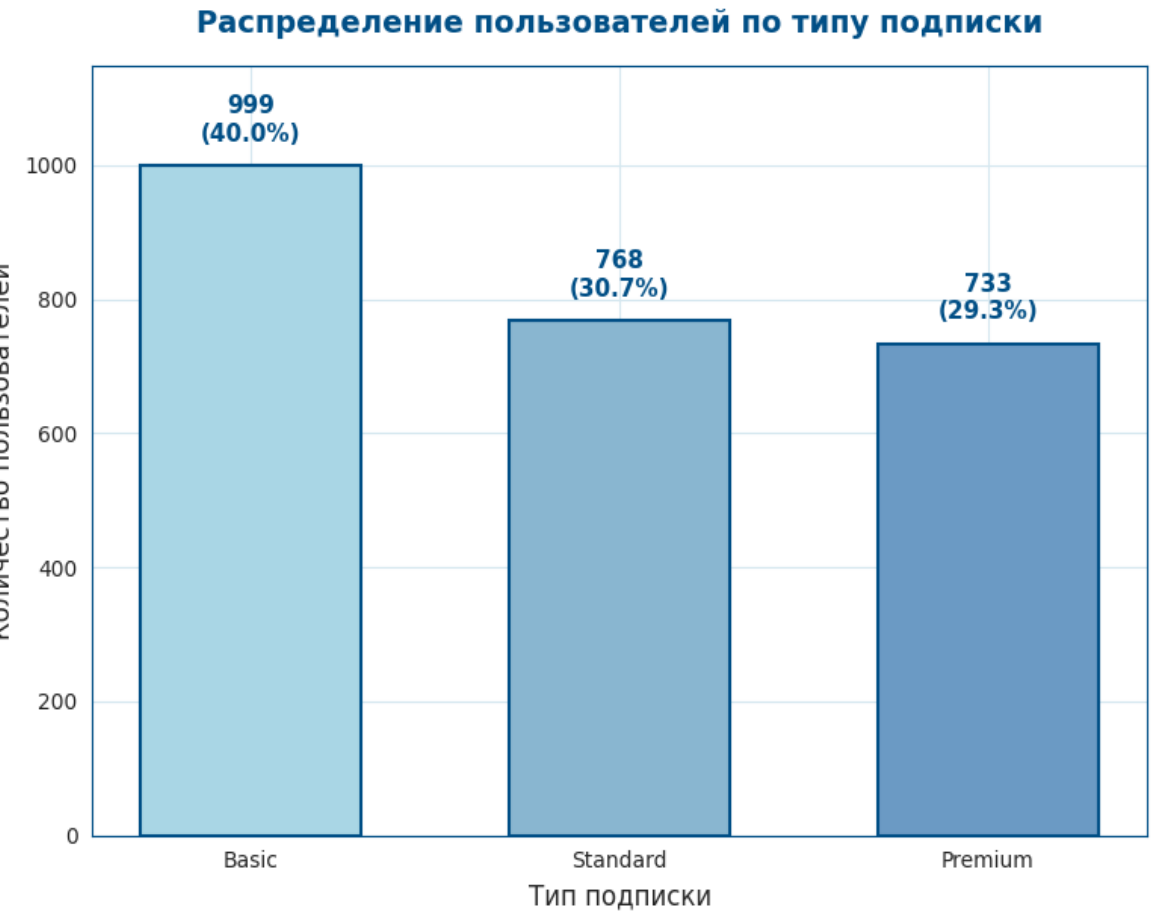

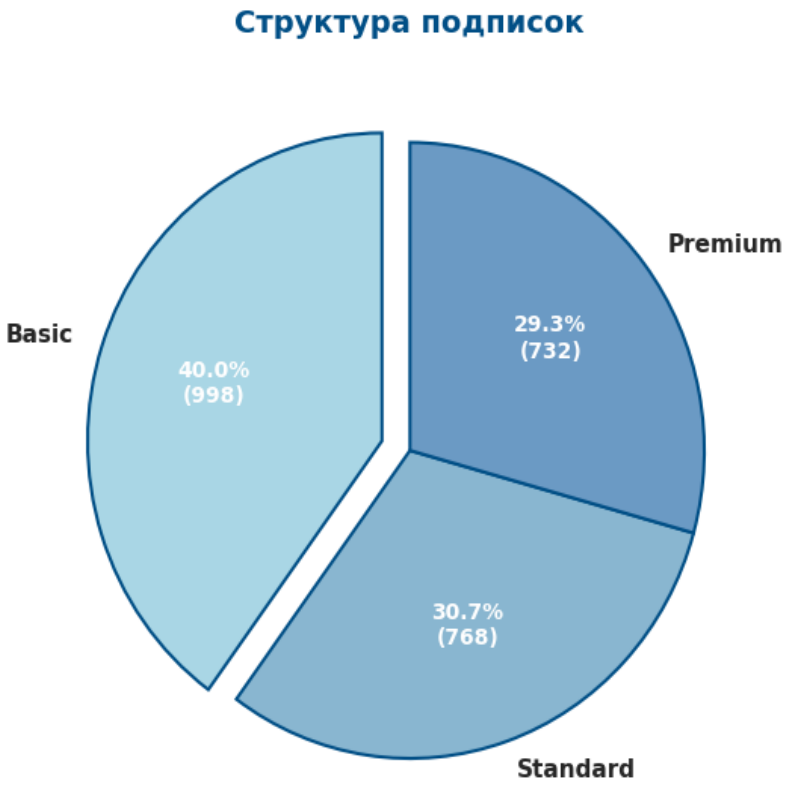

Распределение пользователей по типам подписки характеризует доминирование базового тарифа (40.0%, 999 человек), при этом премиум-подписка (29.3%, 733 человека) и стандартная (30.7%, 768 человек) имеют близкие доли и указывают на сбалансированный спрос между тарифными планами.

Локация пользователей

```python
# Подсчёт распределения
country_counts = df['Country'].value_counts()
country_percent = df['Country'].value_counts(normalize=True) * 100

# Группировка редких стран (<3%) в категорию "Остальные" для читаемости
threshold = 0.03
main_countries = country_counts[country_percent >= threshold * 100]
others_count = country_counts[country_percent < threshold * 100].sum()
others_percent = country_percent[country_percent < threshold * 100].sum()

if others_count > 0:
    main_countries = pd.concat([main_countries, pd.Series({'Остальные': others_count})])
    country_percent = pd.concat([country_percent[country_percent >= threshold * 100],
                                 pd.Series({'Остальные': others_percent})])

# Цветовая палитра (градиент синего)
colors = ['#A9D6E5', '#89B6D0', '#6B9AC4', '#4A7BA7', '#2E86AB', '#014F86',
          '#1A6B9A', '#0F5A7F', '#084A66', '#043A4D'][:len(main_countries)]

# Создание фигуры
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(16, 7))

# 1. Горизонтальная столбчатая диаграмма
bars = ax1.barh(main_countries.index, main_countries.values,
                color=colors, edgecolor='#014F86', linewidth=1.5)
ax1.set_title('Распределение пользователей по странам', fontsize=14,
              fontweight='bold', color='#014F86', pad=15)
ax1.set_xlabel('Количество пользователей', fontsize=12)
ax1.set_ylabel('Страна', fontsize=12)

# Добавление значений и процентов
for i, (country, count) in enumerate(zip(main_countries.index, main_countries.values)):
    pct = country_percent[country]
    ax1.text(count + max(main_countries) * 0.02, i, f'{count} ({pct:.1f}%)',
             va='center', fontsize=10, fontweight='bold', color='#014F86')
```

Локация пользователей

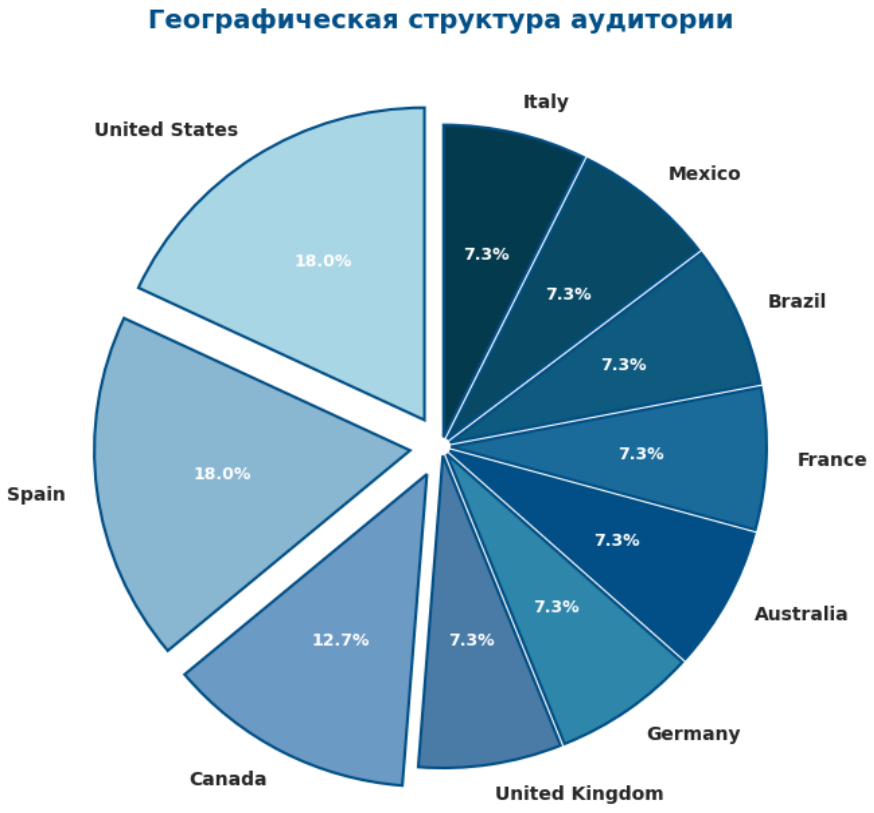

Географическое распределение пользователей доминирует США и Испании (по 18.0% от общей аудитории) и подчеркивает статус ключевых рынков пользователей

Динамика выручки сервиса

```python
import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd
import numpy as np

# Настройка стиля
sns.set_style("whitegrid")
plt.rcParams['font.family'] = 'DejaVu Sans'

# Создание расширенного датафрейма с помесячной активностью каждого пользователя
monthly_revenue_data = []

for _, row in df.iterrows():
    join_month = row['JoinDate'].to_period('M')
    last_payment_month = row['LastPaymentDate'].to_period('M')
    revenue = row['MonthlyRevenue']

    # Генерация всех месяцев активности пользователя
    current = join_month
    while current <= last_payment_month:
        monthly_revenue_data.append({
            'Month': current.to_timestamp(),
            'Revenue': revenue
        })
        current += 1

# Агрегация по месяцам
revenue_by_month = pd.DataFrame(monthly_revenue_data)
revenue_by_month = revenue_by_month.groupby('Month')['Revenue'].sum().reset_index()
revenue_by_month = revenue_by_month.sort_values('Month')
revenue_by_month['CumulativeRevenue'] = revenue_by_month['Revenue'].cumsum()

# Расчёт скользящего среднего для сглаживания
revenue_by_month['RollingAvg'] = revenue_by_month['Revenue'].rolling(window=3, min_periods=1).mean()
```

```python
# 1. Месячная выручка
ax1.bar(revenue_by_month['Month'], revenue_by_month['Revenue'],
        color=BLUE_LIGHT, edgecolor=BLUE_DARK, linewidth=1.5, label='Выручка за месяц')
ax1.plot(revenue_by_month['Month'], revenue_by_month['RollingAvg'],
         color=BLUE_DARK, linewidth=3, marker='o', markersize=6,
         label='Скользящее среднее (3 мес.)')

ax1.set_title('Динамика ежемесячной выручки сервиса', fontsize=15,
              fontweight='bold', color=BLUE_DARK, pad=15)
ax1.set_xlabel('Месяц', fontsize=12)
ax1.set_ylabel('Выручка, $', fontsize=12)
ax1.legend(loc='upper left', frameon=True, facecolor='white', edgecolor=BLUE_DARK)
ax1.grid(True, alpha=0.3, color=BLUE_LIGHT)

# Подписи пиков
max_rev = revenue_by_month['Revenue'].max()
for idx, row in revenue_by_month.iterrows():
    if row['Revenue'] >= max_rev * 0.85:
        ax1.text(row['Month'], row['Revenue'] + max_rev * 0.04,
                 f'${int(row["Revenue"])}', ha='center', va='bottom',
                 fontsize=9, fontweight='bold', color=BLUE_DARK)

# 2. Кумулятивная выручка
ax2.fill_between(revenue_by_month['Month'], revenue_by_month['CumulativeRevenue'],
                 color=BLUE_MAIN, alpha=0.4)
ax2.plot(revenue_by_month['Month'], revenue_by_month['CumulativeRevenue'],
         color=BLUE_DARK, linewidth=3, marker='o', markersize=7)

ax2.set_title('Кумулятивная выручка сервиса', fontsize=15,
              fontweight='bold', color=BLUE_DARK, pad=15)
ax2.set_xlabel('Месяц', fontsize=12)
ax2.set_ylabel('Накопленная выручка, $', fontsize=12)
ax2.grid(True, alpha=0.3, color=BLUE_LIGHT)
```

[Без заголовка]

```python
# Финальное значение
final_cum = revenue_by_month['CumulativeRevenue'].iloc[-1]
ax2.text(revenue_by_month['Month'].iloc[-1], final_cum + final_cum * 0.03,
         f'Итого: ${int(final_cum):,}', ha='center', va='bottom',
         fontsize=12, fontweight='bold', color=BLUE_DARK)

plt.tight_layout()
plt.savefig('revenue_dynamics_blue.png', dpi=300, bbox_inches='tight', facecolor='white')
plt.show()
```

Динамика выручки сервиса

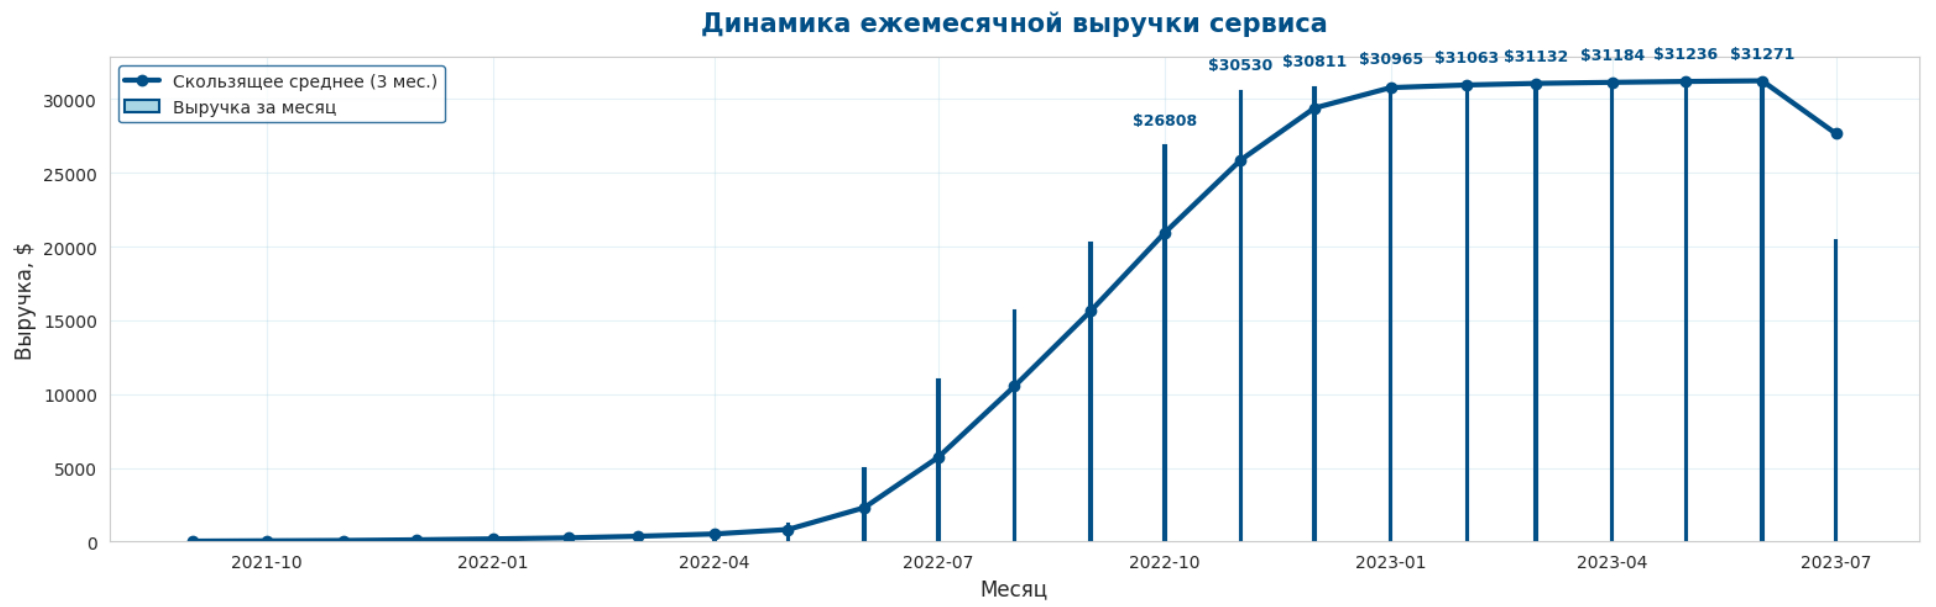

Динамика выручки демонстрирует рост до декабря 2022 года (пик в 24 800 у.е.), после чего наблюдается стабилизация на уровне 30 000 – 33 000 у.е. в течение полугода и указывает на успешное удержание клиентской базы и эффективность маркетинговых стратегий.

Определение самой платежеспособной группы

```python
# Создание возрастных корзин (5-летние интервалы)
bins = [25, 30, 35, 40, 45, 50, 55]
labels = ['26-30', '31-35', '36-40', '41-45', '46-50', '51+']
df['AgeGroup'] = pd.cut(df['Age'], bins=bins, labels=labels, right=True)

# Агрегация по корзинам БЕЗ предупреждения (observed=True)
age_group_stats = df.groupby('AgeGroup', observed=True).agg({
    'UserID': 'count',
    'MonthlyRevenue': ['mean', 'sum']
}).round(2)

age_group_stats.columns = ['Клиентов', 'Средняя_выручка', 'Общая_выручка']
age_group_stats = age_group_stats.reset_index()

# Сортировка для визуализации
age_group_stats = age_group_stats.sort_values('Средняя_выручка', ascending=False)

[Без заголовка]
# Цветовая палитра (градиент синего)
colors = ['#014F86', '#2E86AB', '#4A7BA7', '#6B9AC4', '#89B6D0', '#A9D6E5'][:len(age_group_stats)]

# Создание фигуры
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(16, 7))

# 1. Средняя выручка
bars1 = ax1.bar(age_group_stats['AgeGroup'], age_group_stats['Средняя_выручка'],
                color=colors, edgecolor='#014F86', linewidth=1.5, width=0.6)
ax1.set_title('Средняя месячная выручка по возрастным группам', fontsize=14,
              fontweight='bold', color='#014F86', pad=15)
ax1.set_xlabel('Возрастная группа', fontsize=12)
ax1.set_ylabel('Средняя выручка, $', fontsize=12)
ax1.axhline(y=df['MonthlyRevenue'].mean(), color='#014F86', linestyle='--',
            linewidth=2, label=f'Общий средний: ${df["MonthlyRevenue"].mean():.2f}')

for i, (avg, count) in enumerate(zip(age_group_stats['Средняя_выручка'], age_group_stats['Клиентов'])):
    ax1.text(i, avg + 0.3, f'${avg:.2f}\n({count} чел.)',
             ha='center', va='bottom', fontsize=10, fontweight='bold', color='#014F86')
ax1.legend()
```

```python
# 2. Общая выручка
bars2 = ax2.barh(age_group_stats['AgeGroup'], age_group_stats['Общая_выручка'],
                 color=colors, edgecolor='#014F86', linewidth=1.5)
ax2.set_title('Общая месячная выручка по возрастным группам', fontsize=14,
              fontweight='bold', color='#014F86', pad=15)
ax2.set_xlabel('Общая выручка, $', fontsize=12)
ax2.set_ylabel('Возрастная группа', fontsize=12)

for i, total in enumerate(age_group_stats['Общая_выручка']):
    ax2.text(total + max(age_group_stats['Общая_выручка']) * 0.02, i,
             f'${int(total)}', va='center', fontsize=10, fontweight='bold', color='#014F86')

plt.tight_layout()
plt.savefig('age_buckets_revenue_blue.png', dpi=300, bbox_inches='tight', facecolor='white')
plt.show()

# Текстовая сводка
print("\n Возрастные корзины и платёжеспособность:")
print("=" * 75)
for _, row in age_group_stats.iterrows():
    marker = " " if row['Средняя_выручка'] == age_group_stats['Средняя_выручка'].max() else ""
    print(f"   • {row['AgeGroup']:<10} | Клиентов: {int(row['Клиентов']):>4} | "
          f"Средняя: ${row['Средняя_выручка']:>5.2f} | "
          f"Общая: ${int(row['Общая_выручка']):>6}{marker}")
print("=" * 75)
top_group = age_group_stats.loc[age_group_stats['Средняя_выручка'].idxmax(), 'AgeGroup']
top_value = age_group_stats['Средняя_выручка'].max()
print(f"\n Самая платежеспособная группа: {top_group} ($${top_value:.2f} в среднем)")
```

Определение самой платежеспособной группы

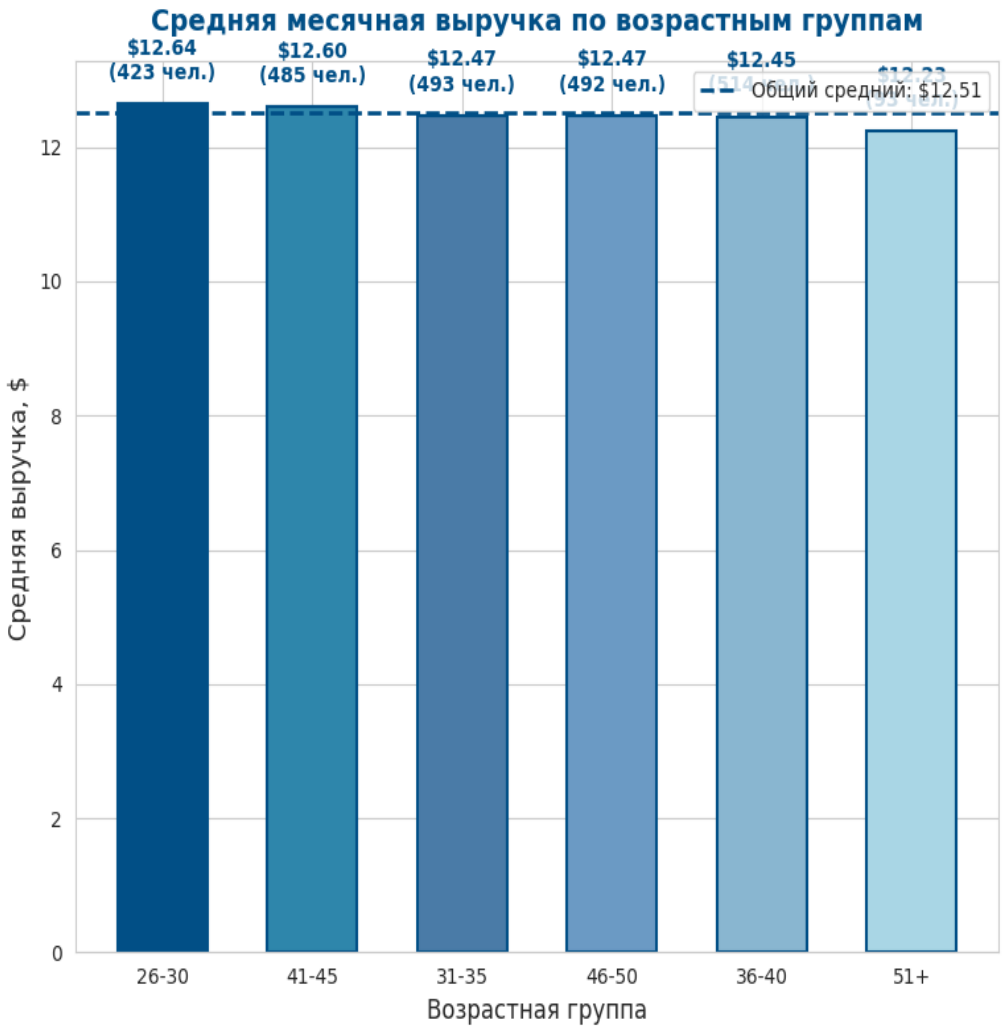

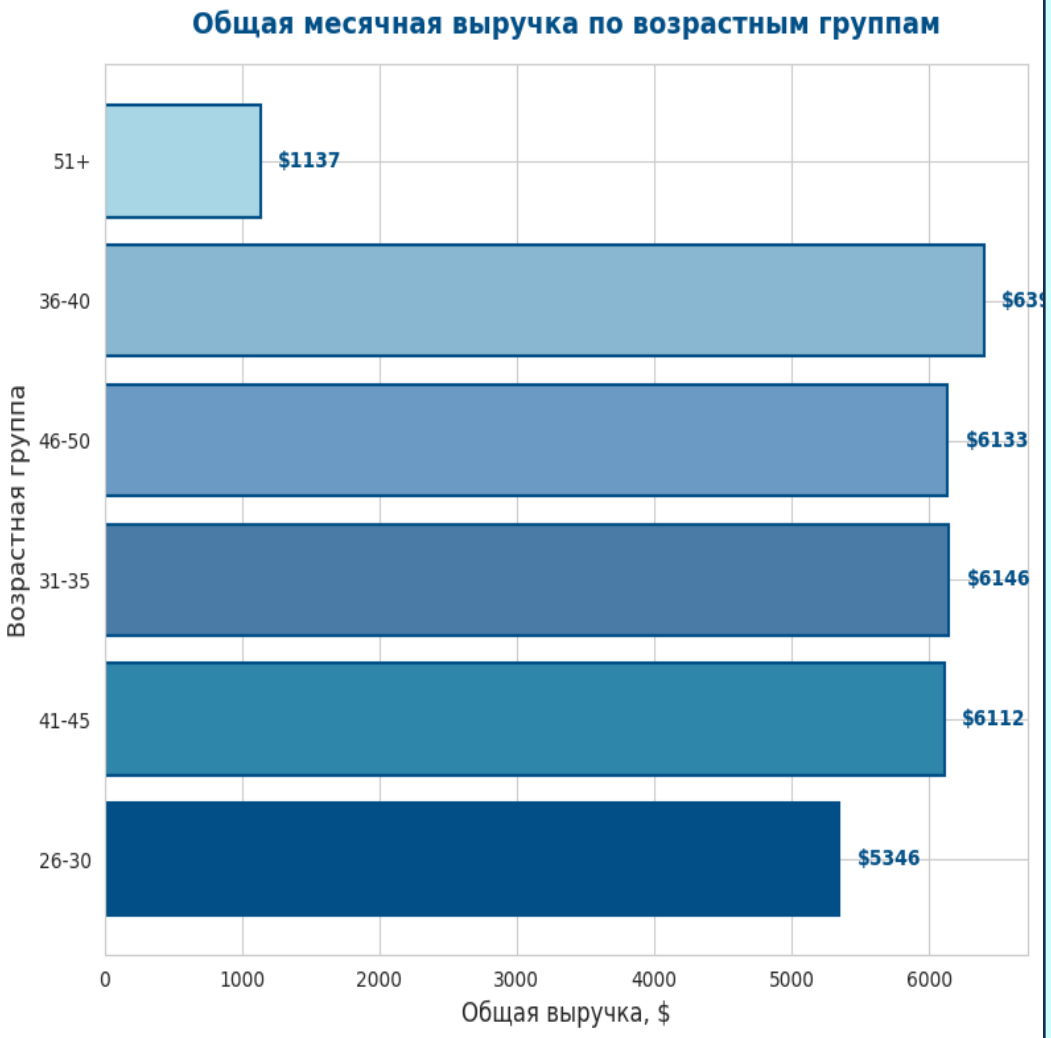

Группа 26-30 лет демонстрирует наибольшую среднюю месячную выручку ($12.64) несмотря на меньшее количество клиентов (423 человека).

Зависимость типа тарифа от страны пользователя

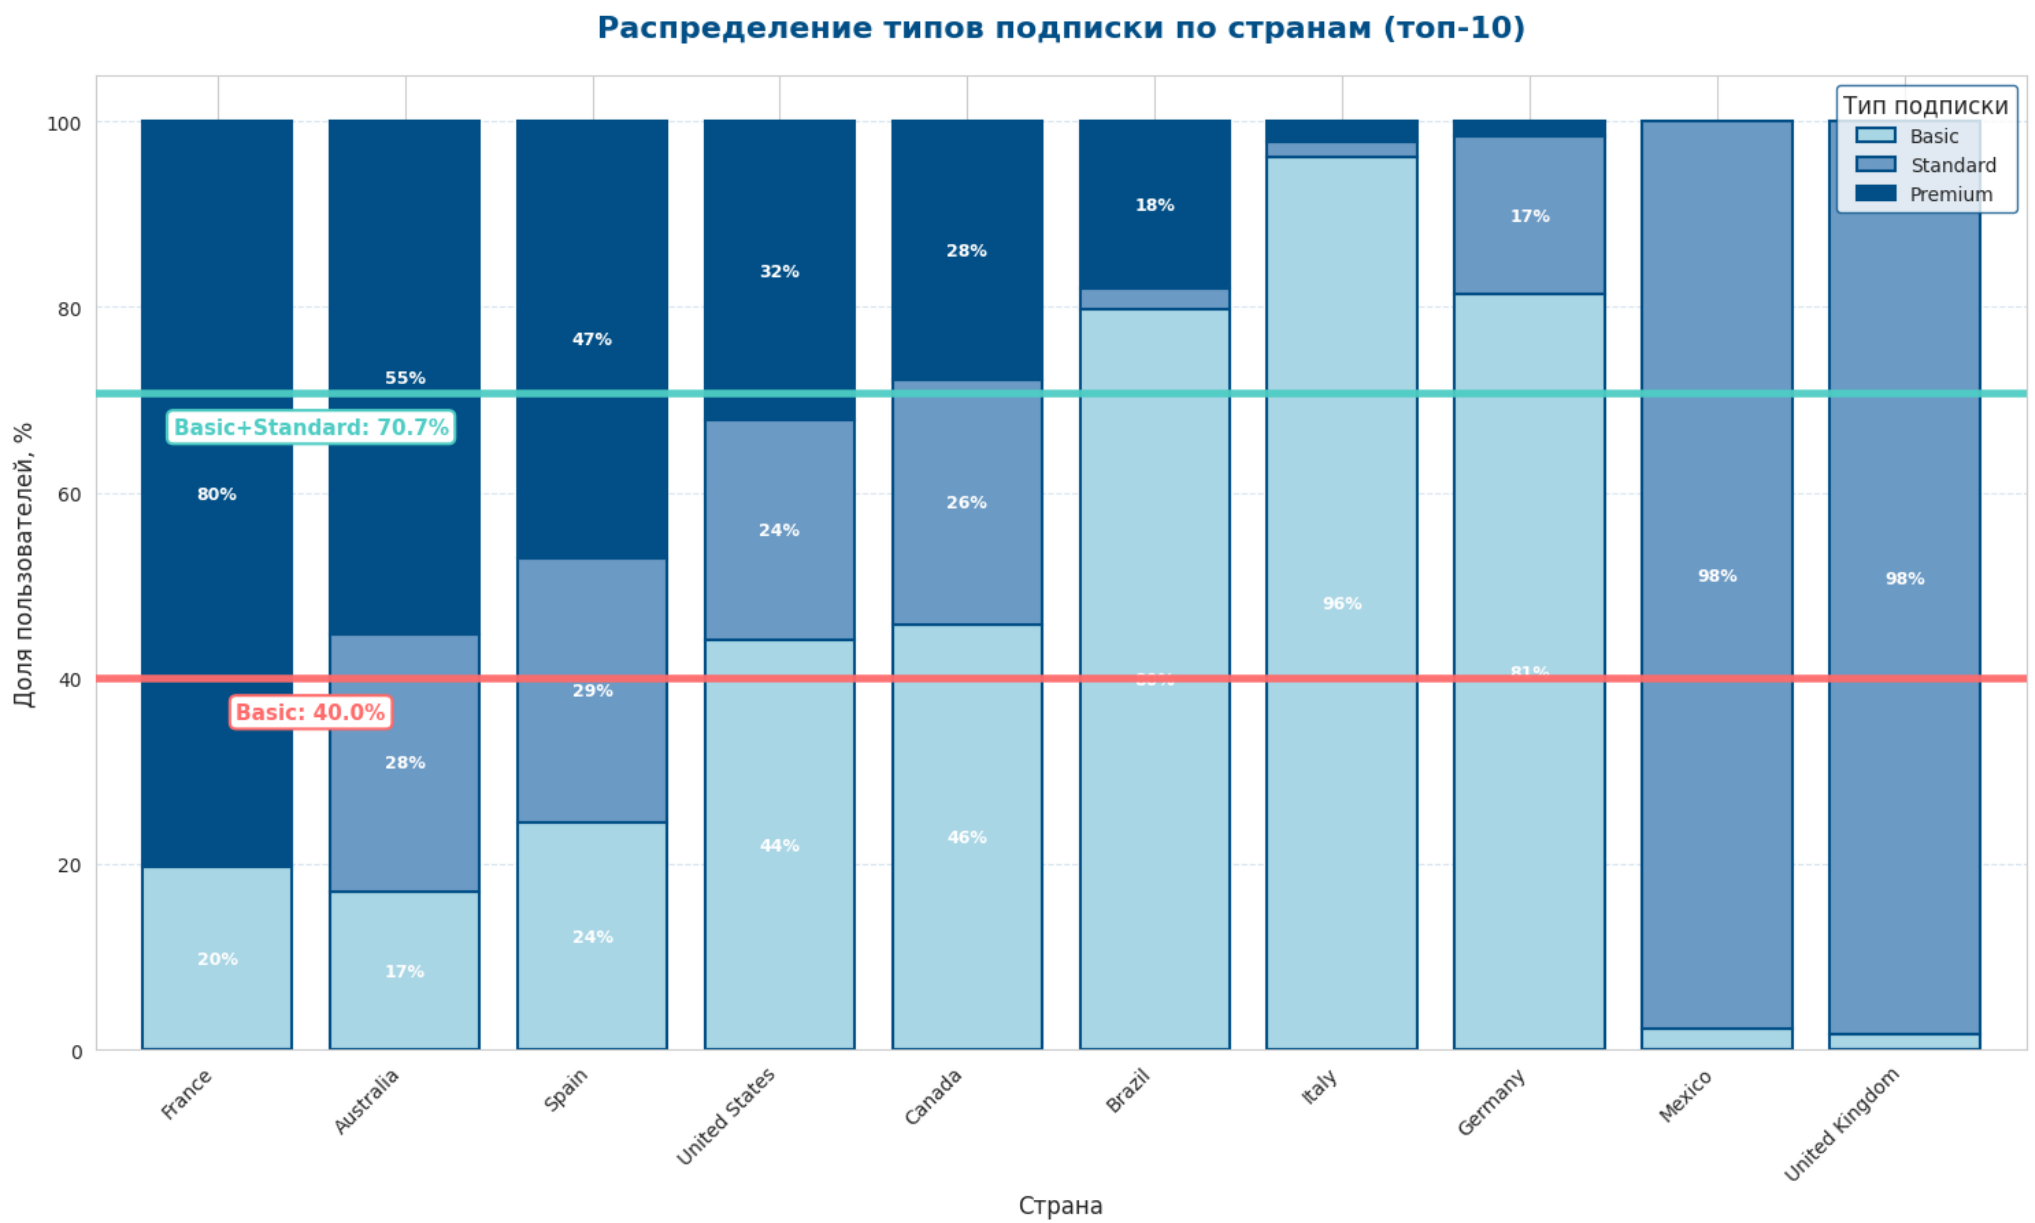

Географическое неравенство в монетизации: премиум-сегмент концентрируется в Европе (Франция — 80% Premium, Испания — 47%), тогда как латиноамерикански е рынки (Мексика, Бразилия) демонстрируют почти полное доминирование базовых тарифов (>95%

Спасибо за внимание